Բովանդակություն

Ներածություն 5
ԳԼՈՒԽ 1. Գրականության վերլուծական ակնարկ 7
1.1 Առկա համակարգերի հետազոտություն 7
1.2 Օգտագործած գործիքամիջոցների նկարագրություն 10
1.3 Հիվանդությունների ախտորոշման համակարգի իրականացման մեթոդների ուսումնասիրություն 14
1.4 Խնդրի դրվածք 17
ԳԼՈՒԽ 2. Տվյալների մշակում և մոդելի ուսուցում 19
2.1 Տվյալների հավաքագրում և մշակում 19
2.2 Հիվանդության պիտակի նույնականացում և դասակարգում 20
2.3 Տվյալների հավաքածուի բաժանում 22
2.4 Մեքենայական մոդելի ուսուցում և օպտիմիզատորի ընտրություն 24
ԳԼՈՒԽ 3. Համակարգի ծրագրային իրականացում 39
3.1 Վեբ ինտերֆեյսի մշակում 39
3.2 Մշակված գործիքամիջոցի նկարագրություն 44
Եզրակացություն 46
Գրականության ցանկ 52

Ներածություն

Ժամանակակից բժշկությունը կանգնած է նոր հնարավորությունների առջև՝ կապված արհեստական բանականության (AI) և խորը ուսուցման տեխնոլոգիաների ներդրմամբ։ Այս տեխնոլոգիաները առավելապես օգտագործվում են հիվանդությունների վաղ հայտնաբերման, ախտորոշման ճշգրտության բարձրացման և բուժման ժամանակի կրճատման համար։ Ավելի վաղ փուլերում հիվանդությունը հայտնաբերելը կարևոր է՝ կանխարգելման և արդյունավետ բուժման տեսանկյունից, ինչը զգալիորեն բարելավում է հիվանդների առողջական ցուցանիշները։

Արհեստական բանականության և խորը ուսուցման կիրառումը բժշկության մեջ նպաստում է ոչ միայն տվյալների ավտոմատ վերլուծությանը, այլև բժշկի որոշումների ճշգրտությանը։ Բազմաթիվ հետազոտություններ ցույց են տալիս, որ AI-ն կարող է օգնել հայտնաբերել հիվանդությունները այնպիսի փուլերում, երբ մարդկային աչքով դա դժվար է նկատել։ Այդպիսի տեխնոլոգիաները հատկապես կարևոր են այն դեպքերում, երբ տվյալների հավաքածուն սահմանափակ կամ ոչ լիարժեք է, կամ երբ անհրաժեշտ է մշակել մեծածավալ բազմազան տվյալներ։

Խորը ուսուցումը մեքենայական ուսուցման ճյուղ է, որը հիմնված է արհեստական նեյրոնային ցանցերի վրա։ Նեյրոնային ցանցերը բաղկացած են մի քանի շերտերից, որոնք կարող են սովորել բարդ օրինաչափություններ և կապեր տվյալների մեջ։ Այս տեխնոլոգիան թույլ է տալիս ինքնաբերաբար առանձնացնել և դասակարգել կարևոր հատկանիշները՝ առանց ձեռքով ֆիչերների ստեղծման անհրաժեշտության։

Խորը ուսուցումը լայնորեն կիրառվում է տարբեր ոլորտներում, ներառյալ՝ համակարգչային տեսողություն, բնական լեզվի մշակում և խոսքի ճանաչում։ Բժշկական պատկերների վերլուծությունը հանդիսանում է այդ ոլորտներից մեկը։ Խորը ուսուցման ալգորիթմները կարող են վերլուծել բժշկական պատկերները՝ իմանալով, թե որտեղ են գտնվում հիվանդության նշանները և ինչպիսի ախտորոշում պետք է կատարվի։

Բժշկական պատկերների վերլուծությունը ներառում է պատկերների մշակումը, մեկնաբանումը և դասակարգումը՝ օգտագործելով տարբեր ալգորիթմներ և մեթոդներ։ Ընդհանրապես, պատկերները կարող են լինել ռենտգենյան, ՄՌՏ, ԿՏ կամ ուլտրաձայնային։ Այս պատկերները պարունակում են հսկայական քանակությամբ տվյալներ, որոնք դժվար է վերլուծել միայն մարդկային աչքով։

Խորը ուսուցման ալգորիթմները, մասնավորապես կոնվոլյուցիոն նեյրոնային ցանցերը (CNN), հնարավորություն են տալիս ավտոմատ կերպով գտնել պատկերների կարևոր հատկանիշները՝ օրինակ՝ եզրեր, անկյուններ, հյուսվածքային ձևեր և նախշեր։ CNN-ի շերտերը վարժեցվում են հայտնաբերել տարբեր առանձնահատկություններ՝ սկզբից պարզից մինչև ավելի բարդ օրինաչափություններ։ Մեծ պատկերների վերլուծության դեպքում այս մեթոդը ապահովում է ավելի արագ և ճշգրիտ արդյունքներ, քան ձեռքով վերլուծությունը։

Կոնվոլյուցիոն նեյրոնային ցանցերը կազմված են կոնվոլյուցիոն, pooling և fully connected շերտերից։ Կոնվոլյուցիոն շերտերը օգտագործում են ֆիլտրեր՝ տվյալների առանձնահատկությունները հայտնաբերելու համար։ Pooling շերտերը նվազեցնում են տվյալների չափը, բայց պահպանում կարևոր տեղեկությունները։ Fully connected շերտերը ապահովում են վերջնական դասակարգումը։

CNN-ը սովորում է օգտագործելով ետ տարածման ալգորիթմը (backpropagation) և gradient descent մեթոդը՝ կարգավորելով ֆիլտրերի պարամետրերը և նվազեցնելով կորուստի ֆունկցիան։ Այս գործընթացը թույլ է տալիս ցանցին ավելի ճշգրիտ դասակարգել նոր պատկերները՝ առանց լրացուցիչ մանիպուլյացիաների։

Բժշկական ոլորտում CNN-ն օգտագործվում է բազմաթիվ խնդիրների համար՝ թոքերի հիվանդությունների ախտորոշում, ուռուցքների հայտնաբերում, աչքի հիվանդությունների վերլուծություն և այլն

ԳԼՈՒԽ 1. Գրականության վերլուծական ակնարկ

1.1 Առկա համակարգերի հետազոտություն

Վերջին տարիներին մեքենայական և խորը ուսուցման մեթոդները ակտիվորեն ներգրավվում են հիվանդությունների ախտորոշման գործընթացում: Եթե նախկինում արհեստական բանականության կիրառումը բժշկության մեջ ավելի շատ տեսական բնույթ ուներ, ապա այժմ այն գործնականում օգտագործվում է տարբեր բժշկական կենտրոններում: Այս տեխնոլոգիաները հնարավորություն են տալիս ավտոմատ կերպով վերլուծել պատկերային, կլինիկական և պատմական տվյալները՝ աջակցելով բժշկին որոշումների կայացման փուլում:

Այսօր արդեն մի շարք միջազգային կազմակերպություններ ներդրել են AI համակարգեր, որոնք կիրառվում են տարբեր ոլորտներում: Դրանք կարելի է պայմանականորեն բաժանել մի քանի խմբերի՝ ըստ կիրառման ուղղության և տեխնոլոգիական հիմքի:

Պատկերային ախտորոշման AI համակարգեր

Պատկերային ախտորոշման համակարգերը հիմնականում հիմնված են խորը նեյրոնային ցանցերի վրա, հատկապես՝ կոնվոլյուցիոն ճարտարապետությունների: Դրանք նախատեսված են ՄՌՏ, ԿՏ, ռենտգենյան և ուլտրաձայնային պատկերների ավտոմատ վերլուծության համար:

Այս համակարգերը լայնորեն կիրառվում են, օրինակ, մաշկային ուռուցքների վաղ հայտնաբերման կամ սրտաբանական խնդիրների գնահատման համար: Մոդելները կարողանում են առանձնացնել պատկերներում այնպիսի փոփոխություններ, որոնք երբեմն դժվար է նկատել մարդկային աչքով:

Միջազգային մակարդակում կիրառվող լուծումներից կարելի է նշել՝

- Google DeepMind Health — կիրառում է խորը ուսուցման ալգորիթմներ տարբեր հիվանդությունների վաղ հայտնաբերման նպատակով։
- Siemens Healthineers — առաջարկում է AI-հիմքով լուծումներ ՄՌՏ և ԿՏ պատկերների ավտոմատ վերլուծության համար։
- IBM Watson Health — համադրում է պատկերային տվյալները բժշկական գիտական աղբյուրների հետ։
- Philips IntelliSpace — ապահովում է պատկերների վերլուծություն և որոշումների աջակցություն կլինիկական միջավայրում։

Չնայած բարձր արդյունավետությանը, նման համակարգերը մեծապես կախված են տվյալների որակից։ Բացի այդ, հազվադեպ կամ ոչ ստանդարտ դեպքերում դրանք դեռևս չեն կարող լիարժեք փոխարինել փորձառու մասնագետին։

Կլինիկական տվյալների վերլուծության ML համակարգեր

Պատկերներից բացի, կարևոր դեր ունեն նաև հիվանդի կլինիկական և կենսաբանական տվյալների վրա հիմնված համակարգերը։ Այստեղ կիրառվում են մեքենայական ուսուցման մոդելներ, որոնք սովորում են մեծածավալ տվյալներից և կարողանում են գնահատել հիվանդության զարգացման հավանականությունը։ Այս մոտեցումը կիրառվում է լաբորատոր արդյունքների, գենետիկ տվյալների և կենսանիշերի վերլուծության ժամանակ։ Որոշ համակարգեր կարողանում են նաև մշակել բժշկական պատմությունը և հայտնաբերել ռիսկի գործոններ, որոնք անմիջապես տեսանելի չեն։

Օրինակ՝

- IBM Watson Health — համադրում է կլինիկական տվյալները գիտական հրապարակումների հետ և առաջարկում բուժման տարբերակներ։
- Epic Systems — կիրառում է AI գործիքներ հիվանդների ռիսկերի գնահատման և տվյալների ավտոմատ վերլուծության համար։

Այս համակարգերի հիմնական սահմանափակումը տվյալների ծավալն ու որակն են։ Անբավարար կամ անհամաչափ տվյալների դեպքում մոդելի կանխատեսումները կարող են լինել ոչ բավարար ճշգրիտ։

Decision-Support համակարգեր

Decision-Support կամ բժշկական որոշումների աջակցման համակարգերը նախատեսված են ոչ թե ինքնուրույն ախտորոշման, այլ բժշկին օգնելու համար։ Դրանք վերլուծում են առկա տվյալները և առաջարկում հնարավոր ախտորոշումներ կամ բուժման պլաններ։ Նման համակարգերը հատկապես օգտակար են բարդ կամ բազմագործոն դեպքերում, որտեղ անհրաժեշտ է համադրել տարբեր աղբյուրներից ստացված տեղեկատվությունը։ Այս ուղղությամբ կիրառվող լուծումներից մեկն է կրկին IBM Watson Health-ը, որը կարողանում է համադրել հիվանդի տվյալները բժշկական գրականության հետ և առաջարկել համապատասխան բուժման ռազմավարություն։ Այնուամենայնիվ, վերջնական որոշումը շարունակում է մնալ բժշկի պատասխանատվության տակ, քանի որ համակարգերը չեն կարող ամբողջությամբ հաշվի առնել բոլոր կլինիկական նրբությունները։

Համեմատական գնահատում

Վերլուծելով առկա համակարգերը՝ կարելի է նկատել, որ դրանցից յուրաքանչյուրը ունի իր կիրառման ոլորտը։ Պատկերային ախտորոշման համակարգերը առավել արդյունավետ են տեսողական տվյալների մշակման դեպքում, իսկ կլինիկական տվյալների վերլուծության մոդելները առավել օգտակար են ռիսկի գնահատման և կանխատեսման խնդիրներում։ Decision-Support համակարգերը նպաստում են բժշկական որոշումների արագացմանը։

Չնայած առկա սահմանափակումներին՝ տվյալների որակ, համատեղելիության խնդիրներ և էթիկական հարցեր, վերջին տարիների հետազոտությունները ցույց են տալիս, որ AI տեխնոլոգիաների կիրառումը զգալիորեն բարելավում է

ախտորոշման արագությունն ու ճշգրտությունը: Սա, իր հերթին, կարող է նպաստել հիվանդությունների վաղ հայտնաբերմանը և բուժման արդյունավետության բարձրացմանը:

1.2 Օգտագործած գործիքամիջոցների նկարագրություն

Սույն ավարտական աշխատանքի իրականացման համար կիրառվել են ժամանակակից ծրագրային գործիքամիջոցներ, գրադարաններ և մշակման միջավայրեր, որոնք ապահովում են խորը ուսուցման մոդելների կառուցումը, վերապատրաստումը, գնահատումը և գործնական կիրառումը:

Հետազոտության ողջ ծրագրային մասի հիմքում ընկած է Python ծրագրավորման լեզուն: Python-ը բարձր մակարդակի, ինտերպրետացվող, ընդհանուր նշանակության ծրագրավորման լեզու է, որն առաջին անգամ ներկայացվել է Գուիդո վան Ռոսումի կողմից 1991 թվականին: Լեզուն առանձնանում է իր կարդալու և գրելու հարմարությամբ, ինչն այն դարձրել է գիտական հաշվարկների, տվյալների վերլուծության և արհեստական բանականության ոլորտի ստանդարտ: Python-ի ամենաուշագրավ հատկություններից է դինամիկ տիպիզացիան, ինչը թույլ է տալիս արագ նախատիպավորում իրականացնել՝ առանց փոփոխականների տեսակները նախապես հայտարարելու: Լեզուն ունի բազմաօրինակ ժառանգություն, ֆունկցիոնալ ծրագրավորման տարրեր, ինչպես նաև ընդլայնված ստանդարտ գրադարան, որն ընդգրկում է ֆայլային համակարգի, ցանցի, մաթեմատիկայի և ձևաչափման բազմաթիվ գործիքներ: Սույն աշխատանքում Python-ն օգտագործվել է մոդելների կառուցման, տվյալների նախնական մշակման, ուսուցման, գնահատման և վեբ ծառայության ինտեգրման ողջ գործընթացում:

Խորը ուսուցման մոդելների ճարտարապետության ձևավորման, կազմաձևման և վերապատրաստման համար օգտագործվել է TensorFlow բաց կոդով գրադարանը՝ Keras բարձր մակարդակի API-ի հետ համատեղ: TensorFlow-ն մշակվել է Google-ի Brain թիմի կողմից և 2015 թվականին հրապարակվել է բաց կոդով լիցենզիայով: Այն ապահովում է

արդյունավետ թվային հաշվարկներ թենզորների (բազմաչափ մատրիցների) վրա՝ աջակցելով ինչպես CPU-ի, այնպես էլ GPU-ի արագացված հաշվարկներին: Keras-ը TensorFlow-ի ներկառուցված բարձր մակարդակի ինտերֆեյսն է, որն ապահովում է հաջորդական (Sequential) և ֆունկցիոնալ (Functional) API-ների միջոցով նեյրոնային ցանցերի կառուցումն ու վերապատրաստումը՝ նվազագույն կոդով: Keras-ի շնորհիվ հնարավոր եղավ հեշտությամբ ավելացնել Conv2D, MaxPooling2D, Dense, Dropout և BatchNormalization շերտեր, ինչպես նաև կանչել fit(), evaluate() և predict() մեթոդները ուսուցման ողջ ցիկլը կառավարելու համար: Այս գրադարանների կիրառումը զգալիորեն արագացրեց փորձարկումների ցիկլը և ապահովեց կոդի ընթեռնելիությունը:

NumPy (Numerical Python) գրադարանը հանդիսանում է գիտական հաշվարկների հիմնաքարն Python-ի էկոհամակարգում: Այն ապահովում է բազմաչափ զանգվածների (ndarray) արդյունավետ ստեղծում, մշակում և մաթեմատիկական գործողությունների կատարում: NumPy-ի հիմնական առավելությունն այն է, որ ի տարբերություն Python-ի ներկառուցված ցուցակների, ndarray-ի գործողությունները կատարվում են ծրագրաշարի ցածր մակարդակում՝ C լեզվի կոդի վրա, ինչն ապահովում է արագ հաշվարկ մեծ ծավալի տվյալների դեպքում:Սույն աշխատանքում NumPy-ն կիրառվել է պատկերների մատրիցային ներկայացման, pixel-ային արժեքների նորմալացման, արդյունքների կուտակման, ինչպես նաև Occlusion Sensitivity Map-ի հաշվարկման ժամանակ զանգվածային գործողություններ կատարելու նպատակով:

Արդյունքների վիզուալիզացման համար կիրառվել է Matplotlib գրադարանը, որը Python-ի ամենատարածված գծապատկերների կառուցման գործիքն է: Matplotlib-ը ստեղծվել է Ջոն Հանտերի կողմից 2003 թվականին և ի սկզբանե նախատեսված էր MATLAB-ի վիզուալիզացիոն ֆունկցիոնալությունը Python-ում կրկնօրինակելու համար: Գրադարանն ապահովում է ստատիկ, ինտերակտիվ և անիմացիոն գծապատկերների կառուցում, ինչպես նաև պատկերային ֆայլերի ձևաչափերի լայն շրջանակ (PNG, SVG, PDF և այլն):Աշխատանքի ընթացքում Matplotlib-ի pyplot մոդուլի միջոցով կառուցվել են ուսուցման ու վավերացման ճշգրտության և կորստի փոփոխությունների գրաֆիկները,

F1-score-ի դինամիկան ըստ էպոխների, ROC կորերն ու AUC արժեքները, ինչպես նաև Occlusion Sensitivity Map-ի ջերմաքարտեզային ձևաչափը:

Scikit-learn (sklearn) բաց կոդով գրադարանը Python-ի մեքենայական ուսուցման ամենահայտնի գործիքակազմն է, որն ապահովում է դասակարգման, ռեգրեսիայի, կլաստերավորման, ծավալների կրճատման, ինչպես նաև տվյալների նախամշակման ալգորիթմների համապարփակ հավաքածու: Scikit-learn-ն աշխատում է NumPy-ի ndarray-ների հետ, ինչն ապահովում է ամուր ինտեգրացիա թվային հաշվողական ողջ էկոհամակարգի հետ: Ավարտական աշխատանքում scikit-learn-ն օգտագործվել է հիմնականում մի քանի նպատակով՝ train/test բաժանման (train_test_split) իրականացման, F1-score, accuracy, precision, recall, ROC-AUC մետրիկաների հաշվարկման (classification_report, roc_curve, auc ֆունկցիաների կիրառմամբ):

OpenCV բաց կոդով համակարգչային տեսլականի գրադարանն օգտագործվել է պատկերների հետ կապված մշակման գործողությունների իրականացման համար: OpenCV-ն սկզբնապես մշակվել է Intel-ի կողմից, իսկ 2000 թվականից ի վեր հասանելի է բաց կոդով լիցենզիայով: Գրադարանն ապահովում է ծրագրային ինտերֆեյս Python, C++, Java և MATLAB լեզուների համար և պարունակում է ավելի քան 2500 օպտիմիզացված ալգորիթմ՝ պատկերների մշակման, վիդեո վերլուծության, դեմքի ճանաչման և այլ ոլորտների համար: Սույն հետազոտությունում OpenCV-ն կիրառվել է Occlusion Sensitivity Map-ի ջերմաքարտեզի չափափոխման (cv2.resize), ուշադրության կարևոր հատվածների ուրվագծման (cv2.findContours, cv2.boundingRect, cv2.rectangle), ինչպես նաև պատկերի գունային ալիքների (BGR/RGB) փոխարկման (cv2.cvtColor) գործողությունների ժամանակ:

Ախտորոշիչ մոդելի հիման վրա վեբ ծառայության ստեղծման համար ընտրվել է Flask միկրո framework-ը: Flask-ը Python-ի բաց կոդով, թեթև վեբ framework է, որն ստեղծվել է Արմին Ռոնաչերի կողմից 2010 թվականին WSGI (Web Server Gateway Interface) ստանդարտի հիման վրա: Flask-ն ի տարբերություն ավելի ծավալուն framework-ների (Django), հիմնված է մինիմալ ճարտարապետության սկզբունքի վրա. այն ի սկզբանե ապահովում է միայն երթուղավորումը (routing) և HTTP հարցումների/արձագանքների

կառավարումը, մինչդեռ մնացած բոլոր ֆունկցիոնալությունները ավելացվում են կոնկրետ կարիքների համաձայն։Հավելվածի կառուցման ժամանակ Flask-ն ապահովել է HTTP POST հարցումների ընդունումն ու մշակումը, ֆայլերի վերբեռնումն ու պահպանումը, ինչպես նաև JSON ձևաչափով ախտորոշիչ արդյունքների ու Base64 կոդավորված վիզուալիզացիոն պատկերների վերադարձը։

Մոդելների ուսուցման, փորձարկման և արդյունքների վիզուալ վերլուծության ողջ գործընթացն իրականացվել է Jupyter Notebook ինտերակտիվ մշակման միջավայրում։ Jupyter Notebook-ը բաց կոդով վեբ հավելված է, որն ապահովում է կոդի, մաթեմատիկական բանաձևերի, վիզուալիզացիոն գրաֆիկների և բացատրական տեքստի համատեղումը մեկ փաստաթղթի (notebook) շրջանակներում։ Այն հատկապես տարածված է տվյալների գիտության, մեքենայական ուսուցման և ակադեմիական հետազոտությունների ոլորտում՝ կոդ-արդյունք-բացատրություն փոխհատվող ցիկլի հարմարությամբ։ Jupyter-ի բջջային (cell-based) կառուցվածքը հնարավորություն է տվել փուլ առ փուլ փորձարկել տարբեր ճարտարապետական տարբերակներ, ակնթարթորեն տեսնել գրաֆիկական արդյունքները (loss/accuracy կորեր, confusion matrix, ROC կորեր) և արձանագրել փորձարկումների ողջ ընթացքը՝ ապահովելով հետազոտության վերարտադրելիությունը։

Pillow-ն Python Imaging Library-ի ժամանակակից ֆորկն է, որն ապահովում է պատկերի ֆայլերի բացման, մշակման, ձևաչափի փոխարկման և պահպանման ֆունկցիոնալությունը Python-ի ծրագրային բաղադրիչների ողջ շղթայում։ Գրադարանն ապահովում է JPEG, PNG, BMP, TIFF, GIF ձևաչափերի աջակցություն, ինչպես նաև պատկերի չափափոխում, կտրում, գունային ձևաչափերի (RGB, RGBA, L) փոխակերպում և pixel-ային արժեքների ուղղակի հասանելիություն։Ավարտական աշխատանքում Pillow-ն կիրառվել է URL-ով տրամադրված բժշկական պատկերների ներբեռնման ու բացման, RGB ձևաչափի ապահովման, ինչպես նաև Occlusion Sensitivity Map-ի վիզուալիզացիոն ելքային ֆայլի պահպանման գործողությունների ժամանակ։

1.3 Հիվանդությունների ախտորոշման համակարգի իրականացման մեթոդների ուսումնասիրություն

Վերջին տարիներին առողջապահական ոլորտում արագ զարգացում են ապրում ավտոմատ ախտորոշման համակարգերը: Եթե նախկինում բժշկական պատկերների վերլուծությունը ամբողջությամբ հիմնված էր մասնագետի փորձի վրա, ապա այժմ այդ գործընթացում ակտիվորեն կիրառվում են մեքենայական և խորը ուսուցման մեթոդներ: Այս տեխնոլոգիաները հնարավորություն են տալիս մշակել մեծ ծավալի բժշկական տվյալներ և հայտնաբերել օրինաչափություններ, որոնք հաճախ դժվար է նկատել մարդու կողմից:

Այս համակարգերի հիմքում հիմնականում գտնվում են խորը նեյրոնային ցանցերը, հատկապես կոնվոլյուցիոն նեյրոնային ցանցերը (CNN), որոնք լայնորեն կիրառվում են պատկերների վերլուծության խնդիրներում:

Կոնվոլյուցիոն նեյրոնային ցանցեր (CNN)

CNN-ները ներկայումս համարվում են բժշկական պատկերների մշակման ամենաարդյունավետ մոտեցումներից մեկը: Դրանք բաղկացած են մի քանի շերտերից, որոնցից յուրաքանչյուրն ունի իր հատուկ դերը՝ սկսած պարզ եզրերի հայտնաբերումից մինչև բարդ կառուցվածքների ճանաչում:

Այս ցանցերի կարևոր առանձնահատկությունն այն է, որ դրանք ինքնուրույն սովորում են պատկերներում առկա կարևոր հատկանիշները՝ առանց նախապես սահմանված կանոնների: Օրինակ՝ կարող են տարբերակել հյուսվածքների կառուցվածքային փոփոխությունները, բորբոքային օջախները կամ ուռուցքային գոյացությունները:

Բժշկական ոլորտում լայնորեն կիրառվում են մի շարք հայտնի ճարտարապետություններ՝

VGG19, ResNet50, DenseNet121 և EfficientNet-B3:

Օրինակ՝ ResNet50-ը առանձնանում է իր residual կապերով, որոնք թույլ են տալիս կառուցել խոր ցանցեր՝ խուսափելով գրադիենտի մարելու խնդրից։ DenseNet121-ում շերտերը սերտորեն կապված են միմյանց հետ, ինչը բարելավում է ֆիչերների փոխանցումը ամբողջ ցանցով։ EfficientNet մոդելները փորձում են հավասարակշռել ճշգրտությունն ու հաշվարկային ծախսերը։

CNN-ները կիրառվում են տարբեր խնդիրներում՝ COVID-19-ի և թոքաբորբի հայտնաբերում ռենտգենյան կամ ԿՏ պատկերներից, մաշկային ուռուցքների դասակարգում, ինչպես նաև սրտային հիվանդությունների գնահատում ՄՌՏ կամ ԷՔԳ տվյալների հիման վրա։

Փոխանցման ուսուցում (Transfer Learning)

Բժշկական տվյալների հավաքածուները հաճախ սահմանափակ են, քանի որ դրանց հավաքագրումը ժամանակատար և թանկ գործընթաց է։ Այս պայմաններում ամբողջական խորը ցանց զրոյից ուսուցանելը միշտ չէ, որ արդյունավետ է։

Այստեղ կիրառվում է փոխանցման ուսուցումը, որի գաղափարը հետևյալն է. օգտագործել արդեն նախապես ուսուցանված մոդել (օրինակ՝ ImageNet տվյալների վրա), և այն հարմարեցնել կոնկրետ բժշկական խնդրին։

Սովորաբար պահվում են նախնական շերտերը, որոնք պատասխանատու են ընդհանուր ֆիչերների հայտնաբերման համար, իսկ վերջնական շերտերը վերապատրաստվում են տվյալ հիվանդության տվյալների հիման վրա։

Օրինակ՝ COVID-19-ի դասակարգման համար հնարավոր է օգտագործել ImageNet-ի վրա ուսուցանված ResNet50 մոդել և միայն վերջնական շերտերը վերապատրաստել տեղական ռենտգենյան պատկերների վրա։ Նման մոտեցմամբ հնարավոր է հասնել շուրջ 95% ճշգրտության՝ նույնիսկ համեմատաբար փոքր տվյալների դեպքում։

Տվյալների նախնական մշակում

Բժշկական պատկերները հաճախ ունեն տարբեր տեխնիկական խնդիրներ՝ աղմուկ, լուսավորության անհամաչափություն կամ ցածր կոնտրաստ: Եթե այդ խնդիրները նախապես չմշակվեն, մոդելի արդյունքները կարող են զգալիորեն տուժել:

Նախնական մշակման փուլում կիրառվում են տարբեր մեթոդներ: Օրինակ՝ CLAHE մեթոդը օգնում է բարելավել կոնտրաստը և ավելի հստակ դարձնել մանր կառուցվածքները: Նորմալիզացիան ապահովում է, որ պիքսելների արժեքները լինեն միասնական տիրույթում, ինչը նպաստում է ուսուցման կայունությանը:

Բացի այդ, լայնորեն կիրառվում է տվյալների արհեստական ընդլայնումը (augmentation)՝ պտույտներ, հայելային արտապատկերում, մասշտաբավորում կամ աղմուկի ավելացում: Եթե ունենք 1000 պատկեր, augmentation-ի միջոցով հնարավոր է ստանալ բազմակի անգամ մեծացված հավաքածու, ինչը նվազեցնում է overfitting-ի ռիսկը և բարձրացնում մոդելի ընդհանուր կայունությունը:

Ուսուցման գործընթացի օպտիմալացում

Խորը ուսուցման մոդելի արդյունավետությունը մեծապես կախված է ոչ միայն ճարտարապետությունից, այլ նաև ուսուցման պարամետրերից: Օպտիմիզատորների ճիշտ ընտրությունը (օրինակ՝ SGD կամ Adam), learning rate-ի կարգավորումը և regularization մեթոդները կարևոր դեր ունեն վերջնական արդյունքի վրա:

Dropout շերտերի կիրառումը ևս օգնում է կանխել overfitting-ը՝ ուսուցման ընթացքում պատահականորեն «անջատելով» որոշ նեյրոններ:

Օրինակ՝ ResNet50 մոդելի ուսուցման ընթացքում Adam օպտիմիզատորի և համապատասխան learning rate-ի կիրառումը կարող է ապահովել շուրջ 96% ճշգրտություն validation տվյալների վրա:

Գնահատման չափորոշիչներ

Ախտորոշիչ համակարգի գնահատումը չի սահմանափակվում միայն accuracy-ով։ Բժշկական խնդիրներում հատկապես կարևոր են Precision-ը և Recall-ը, քանի որ սխալ բացասական կամ սխալ դրական կանխատեսումները կարող են լուրջ հետևանքներ ունենալ։

F1-score-ը կիրառվում է այն դեպքերում, երբ տվյալների բաշխումը անհավասար է։ ROC-AUC ցուցանիշը ևս կարևոր է՝ գնահատելու մոդելի տարբերակիչ կարողությունը տարբեր շեմերի դեպքում։

Օրինակ՝ COVID-19 պատկերների դասակարգման մոդելի դեպքում հնարավոր է ստանալ շուրջ 95% accuracy և մոտ 0.97 ROC-AUC, ինչը վկայում է մոդելի բավական բարձր արդյունավետության մասին։

Մոտեցումների համադրություն

Գործնականում առավել արդյունավետ արդյունք է ստացվում, երբ համադրվում են մի քանի մոտեցումներ՝ CNN ճարտարապետություն, փոխանցման ուսուցում, տվյալների նախնական մշակում և օպտիմիզացիոն մեթոդներ։

Այսպիսի համակցված համակարգերը կարող են կիրառվել հիվանդությունների վաղ փուլում հայտնաբերման, ռիսկերի գնահատման և բժշկական որոշումների աջակցման գործընթացում։

1.4 Խնդրի դրվածք

Այս աշխատանքի խնդիրն է ստեղծել մեքենայական ուսուցման վրա հիմնված համակարգ, որը կկարողանա ավտոմատ կերպով վերլուծել բժշկական պատկերները և հայտնաբերել թոքերի հիվանդությունները։Դրա համար անհրաժեշտ գործառույթներն են՝

- Թոքերի ռենտգենյան պատկերների տվյալների հավաքածուի ձևավորում, ֆիլտրում և նախնական մշակում
- Կոնվոլյուցիոն նեյրոնային ցանցի (CNN) ճարտարապետության նախագծում և վերապատրաստում
- Մոդելի կատարողականի գնահատում՝ ճշգրտության, F1-score-ի և ROC-AUC մետրիկաների հիման վրա
- Ախտորոշիչ մոդելի հիման վրա վեբ հավելվածի մշակում՝ օգտատիրոջ ինտուիտիվ ինտերֆեյսով
- Մոդելի որոշումների բացատրելիության ապահովում՝ Occlusion Sensitivity Map տեխնիկայի կիրառմամբ
- Դասակարգի պատկերները՝ COVID-19, թոքաբորբ, կամ առողջ կատեգորիաներով
- Ունենա հնարավորություն ընդլայնվելու և նոր տվյալների վրա վերապատրաստվելու համար։

ԳԼՈՒԽ 2. Տվյալների մշակում և հիվանդությունների ախտորոշման մոդելի ուսուցում

2.1 Տվյալների հավաքագրում և մշակում

Սկզբնական փուլում տվյալները հավաքվել են Արտաշատի հիվանդանոցի ռադիոլոգիայի բաժնից, որտեղ տրամադրել են ռենտգենների պատկերներ և հիվանդի մասին կարևոր տեղեկություններ: Արդյունքում ֆիլտրել ենք տվյալները՝ ընդգրկելով միայն այն պատկերները, որոնք վերաբերում են թոքերի տարբեր հիվանդություններին: Այս պրոցեսը հնարավորություն է տվել ճիշտ զտել տվյալները՝ պահպանելով միայն անհրաժեշտ տեղեկությունները:

Նախամշակման գործողությունները ներառում էին պատկերի չափի փոփոխումը, պիքսելների արժեքի նորմալացումը և, անհրաժեշտության դեպքում, տվյալների ավելացումը (data augmentation): Կարգավորումներ են կատարվել պատկերի չափսերում՝ պատկերները համապատասխանեցնելու համար ընտրված խորը ուսուցման մոդելների ակնկալվող մուտքային չափերին (224x224x3):

```python
import numpy as np
import tensorflow as tf

def preprocess_image(image_path):
    image = tf.keras.preprocessing.image.load_img(image_path, target_size=(224, 224))
    image = tf.keras.preprocessing.image.img_to_array(image)
    # Apply CLAHE
    lab = cv2.cvtColor(image.astype(np.uint8), cv2.COLOR_RGB2LAB)
    l, a, b = cv2.split(lab)
    clahe_obj = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8,8))
    l = clahe_obj.apply(l)
    lab = cv2.merge((l, a, b))
    image = cv2.cvtColor(lab, cv2.COLOR_LAB2RGB)
    image = image / 255.0
    return image

def create_dataset(df):
    image_paths = df['image_path'].values
    labels = df['label'].values

    images = []
    for path in image_paths:
        image = preprocess_image(path)
        images.append(image)

    images = np.array(images)
    return images, labels
```

Նախամշակման փուլը կատարելագործված է՝ ներառելով Contrast-Limited Adaptive Histogram Equalization (CLAHE) տեխնիկան, որն օգտագործվում է պատկերի մշակման մեջ՝ բարձրացնելով պատկերի կոնտրաստը՝ միաժամանակ կանխելով աղմուկի ուժեղացումը: Հիմնական գաղափարը պատկերը բաժանելն է փոքր, չհամընկնող սալիկների, այնուհետև յուրաքանչյուր սալիկի վրա առանձին կիրառել հիստոգրամի հավասարեցում:

2.2 Հիվանդության պիտակի նույնականացում և դասակարգում

Ստեղծվել է թոքերի հիվանդությունների բոլոր եզակի կատեգորիաների գրանցում, որն օգտագործվել է հետագա վերլուծության և մոդելների համար: Այս քայլը առանցքային էր

դասակարգման առաջադրանքի շրջանակի համապարփակ պատկերացում ձեռք բերելու համար:

Թոքերի եզակի հիվանդությունների հավաքումից հետո սկսվեցին անհատական դասակարգման մի շարք առաջադրանքներ: Յուրաքանչյուր առաջադրանք կենտրոնացած էր առանձին հիվանդությունների անկախ դասակարգման վրա: Մշակվել են դասակարգման բազմաթիվ մոդելներ, որոնցից յուրաքանչյուրը նվիրված է թոքերի մեկ հիվանդությունը այլ դասերից տարբերելուն: Մոդելը դասակարգում է պատկերը երեք հիմնական կատեգորիաների՝ Նորմալ (Normal), Թոքաբորբ (Pneumonia) և COVID-19:

1	image_path	label
3076	jpg\2.16.840.1.113669.632.3.111111.48032512314100.109052.1.2.105540.jpg	Pneumonia
3077	jpg\2.16.840.1.113669.632.3.111111.48032512320800.109052.1.3.105540.jpg	Pneumonia
3078	jpg\2.16.840.1.113669.632.3.111111.48032512381600.109053.1.1.105540.jpg	Normal
3079	jpg\2.16.840.1.113669.632.3.111111.48032512404600.109053.1.2.105540.jpg	Normal
3080	jpg\2.16.840.1.113669.632.3.111111.48032513103600.109054.1.1.105540.jpg	COVID-19
3081	jpg\2.16.840.1.113669.632.3.111111.48032513105200.109054.1.2.105540.jpg	COVID-19
3082	jpg\2.16.840.1.113669.632.3.111111.48032513140100.109055.1.1.105540.jpg	COVID-19
3083	jpg\2.16.840.1.113669.632.3.111111.48032513490700.109058.1.1.105540.jpg	Pneumonia
3084	jpg\2.16.840.1.113669.632.3.111111.48032513524400.109059.1.1.105540.jpg	Pneumonia
3085	jpg\2.16.840.1.113669.632.3.111111.48032513531000.109059.1.2.105540.jpg	Pneumonia
3086	jpg\2.16.840.1.113669.632.3.111111.48032513534400.109059.1.3.105540.jpg	Normal
3087	jpg\2.16.840.1.113669.632.3.111111.48032514005000.109060.1.1.105540.jpg	Pneumonia
3088	jpg\2.16.840.1.113669.632.3.111111.48032514053500.109061.1.1.105540.jpg	COVID-19
3089	jpg\2.16.840.1.113669.632.3.111111.48032514061000.109061.1.2.105540.jpg	COVID-19
3090	jpg\2.16.840.1.113669.632.3.111111.48032514333600.109062.1.1.105412.jpg	Pneumonia

Որպես կորստի ֆունկցիա ընտրվել է Sparse Categorical Crossentropy, քանի որ տվյալները ներկայացված են ամբողջ թվերով (0, 1, 2 դասերը)

```python
import pandas as pd
csv_path = r"C:\Users\Acer\Desktop\label.csv"
df = pd.read_csv(csv_path, header=0)
```

```python
df['label'] = df['label'].map({
    'Normal': 0,
    'Pneumonia': 1,
    'COVID-19': 2
})


df = df.drop(index=0)
```

և հավելյալ one-hot encoding անհրաժեշտ չի եղել: Ելքային շերտում օգտագործվում է Softmax ակտիվացնող ֆունկցիան, որը հաշվարկում է յուրաքանչյուր դասի հավանականությունը և ընտրում է առավել հավանական դասը:

2.3 Տվյալների հավաքածուի բաժանում

Տվյալների հավաքածուն ենթարկվել է բաժանման գործընթացի, որի արդյունքում ստեղծվել են առանձին ուսուցման և փորձարկման ենթաբազմություններ: Այս բաժանումն իրականացվել է մոդելի կատարողականի գնահատումը հեշտացնելու համար՝ ստանդարտ բաժանումներով. 80% հատկացումը վերապատրաստման և 20%՝ թեստավորման համար:

```python
import tensorflow as tf
from sklearn.metrics import roc_auc_score, confusion_matrix, f1_score
from sklearn.model_selection import train_test_split
import numpy as np

# Սահմանել մոդելի կառուցվածքը
def create_model():
    model = tf.keras.models.Sequential([
        tf.keras.layers.Conv2D(32, (3,3), activation='relu', input_shape=(224, 224, 3)),
        tf.keras.layers.MaxPooling2D(2,2),
        tf.keras.layers.Flatten(),
        tf.keras.layers.Dense(128, activation='relu'),
        tf.keras.layers.Dense(3, activation='softmax')
    ])
    return model

# Reshape the data to remove the extra dimension
X = np.squeeze(X, axis=1)  # This removes the second dimension if it's 1

# Տվյալները բաժանում ենք վալիդացիոն և ուսուցման տվյալների
X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2, random_state=42)

# Ստեղծում ենք մոդելը
model = create_model()

# Կոնֆիգուրացիա՝ մոդելը ուսուցանելիս
model.compile(optimizer=tf.keras.optimizers.Adam(),
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

# Ուսուցանում ենք մոդելը (Ավելացնել validation_data)
history = model.fit(X_train, y_train, epochs=10, batch_size=32, validation_data=(X_val, y_val))
```

Train-test split-ը ապահովում է, որ մոդելը կարողանա տեսնել բավարար քանակությամբ տվյալներ ուսուցման ժամանակ, իսկ վալիդացիոն տվյալները թույլ են տալիս գնահատել դրա կատարողականը նոր, չտեսած նմուշների վրա: Validation_data պարամետրը թույլ է տալիս հետևել մոդելի արդյունավետությանը ոչ թե ուսուցման տվյալների, այլ առանձին վալիդացիոն նմուշի վրա: Ընդհանուր տվյալների հավաքածուն կազմել է 3121 կրծքավանդակի ռենտգենյան ճառագայթների պատկեր, որոնք ընդգրկում էին COVID-19-ի, թոքաբորբի և առողջ թոքերի դեպքեր:

2.4 Մեքենայական մոդելի ուսուցում և օպտիմիզատորի ընտրություն

Օպտիմալիզատորներից ընտրվել է Adam-ը, քանի որ այն համատեղում է Momentum և RMSprop մեթոդների առավելությունները: Ուսուցման սկզբնական արագությունը սահմանվել է 0.002: Մոդելի ուսուցումը կատարվել է դինամիկ ուսուցման մեթոդով, ինչը նշանակում է, որ ուսուցման մակարդակը փոփոխվել է՝ կախված մոդելի բարելավման միտումից: Որպես ուսուցման արագության հարմարեցման տեխնիկա ընտրվել է ReduceLROnPlateau մեթոդը, որը նվազեցնում է ուսուցման մակարդակը, երբ բարելավումը դադարում է:Մոդելների ուսուցման ընթացքում օգտագործվել են հետևյալ հիպերպարամետրերը. factor=0.5, patience=10 և min_lr=1e-5: Վավերացման կորուստը մշտադիտարկվել է՝ կիրառելով վաղ դադարեցման (early stopping) մեթոդը: Եթե վավերացման կորուստը 10 հաջորդական դարաշրջանի ընթացքում չի նվազել, ուսուցման գործընթացը դադարեցվել է՝ կանխելու մոդելի հնարավոր գերուսուցումը: Ուսուցման գործընթացը սահմանափակվել է առավելագույնը 20 դարաշրջանով, յուրաքանչյուրում օգտագործվել է 78 խմբաքանակ, և ամբողջ վերապատրաստումը տևել է միջինում 20 րոպե: Մոդելի հիմքում դրված է կոնվոլյուցիոն նեյրոնային ցանց (CNN), որի ճարտարապետությունը ներառում է հաջորդական Conv2D շերտեր՝ ReLU ակտիվացման ֆունկցիայով, MaxPooling2D շերտեր չափի նվազեցման համար, ինչպես նաև Dropout շերտ՝ գերուսուցումը նվազեցնելու նպատակով:

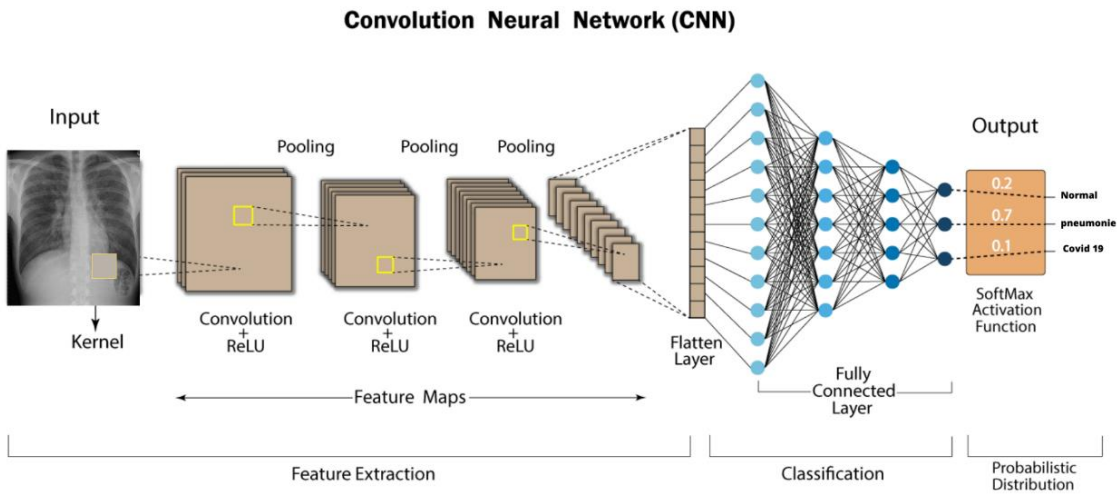

Նկար1.CNN-ի միջոցով հիվանդությունների դասակարգում

Նկար 1-ում պատկերված է Convolutional Neural Network (CNN) մոդելի ամբողջական ընթացքը, որը կիրառվում է թոքերի ռենտգեն պատկերների վերլուծության համար՝ տարբեր հիվանդություններ, օրինակ՝ նորմալ վիճակ, թոքաբորբ կամ Covid-19 հայտնաբերելու նպատակով: Սկզբում մուտք է տրվում թոքերի ռենտգեն նկարը: Այս պատկերից որոշ հատվածներ վերլուծվում են kernel-ների միջոցով, որոնք փնտրում են կարևոր հատկություններ՝ օրինակ եզրեր, կառուցվածքային փոփոխություններ և այլն: Այս հատվածը կոչվում է հատկությունների հանում: Այնուհետև պատկերը անցնում է մի շարք կոնվոլյուցիոն շերտերով, որտեղ յուրաքանչյուր շերտ բացահայտում է նոր առանձնահատկություններ: ReLU ակտիվացնող ֆունկցիան օգնում է մոդելին չնեյտրալացնել բացասական արժեքները: Փուլինգի շերտերը նվազեցնում են պատկերների չափը՝ պահելով հիմնական հատկանիշները, ինչն օգնում է արագացնել և օպտիմալացնել ուսուցման գործընթացը: Վերջին կոնվոլյուցիոն շերտից հետո արդյունքները հարթեցվում են (flatten), որպեսզի հնարավոր լինի դրանք փոխանցել նեյրոնային ցանցի վերջնական՝ լիովին միացված շերտերին: Այստեղ կատարվում է դասակարգման գործընթացը: Ելքային շերտում օգտագործվում է Softmax ակտիվացնող ֆունկցիան, որը հաշվարկում է յուրաքանչյուր դասի հավանականությունը: Օրինակ, եթե արդյունքները լինեն՝ 0.2 նորմալ, 0.7 թոքաբորբ, 0.1 Covid-19, ապա մոդելը կընտրի «թոքաբորբ» դասը՝ որպես ամենահավանական:

Softmax-ը հաշվարկում է յուրաքանչյուր դասի հավանականությունը և ընտրում է առավել հավանական դասը: Կորստի ֆունկցիան ընտրվել է Sparse Categorical Crossentropy, քանի որ տվյալները ներկայացված են ամբողջ թվերով և հավելյալ one-hot encoding անհրաժեշտ չի եղել:

Օգտագործված կորուստի ֆունկցիան արտահայտվում է հետևյալ բանաձևով.

$$\text{Loss} = \sum_{m=1}^{I} * \sum_{n=1}^{J} * t_{mn} \ln y_{mn}$$

որտեղ կրծքավանդակի ռենտգեն նմուշների քանակը նշվում է I-ով, իսկ ռենտգենյան դասերի քանակը՝ J-ով: t_{mn} –ը նշանակում է, որ m-րդ ռենտգեն նմուշը պատկանում է n-րդ ռենտգենյան դասին: y_{mn}-ը ներկայացնում է m-րդ ռենտգեն նմուշի արդյունքը n-րդ դասի համար:

Տվյալների նախնական մշակումն իրականացվել է մի քանի փուլով: Նախ, պատկերի նորմալացումն ապահովել է տվյալների միասնական մասշտաբավորում, ինչը հեշտացրել է մոդելի ուսուցումը: Տվյալների ավելացման (data augmentation) միջոցով ստեղծվել են պատահական փոփոխություններով նոր պատկերներ, ինչպիսիք են պտույտները, հայելային արտացոլումները և լուսավորության փոփոխությունները:

Մոդելի կառուցվածքը կազմված է մի քանի շերտերից, որոնցից առաջինը Conv2D շերտն է, որը պարունակում է 32 ֆիլտր՝ (3,3) չափսով: Այս ֆիլտրերը օգնում են մոդելին հայտնաբերել տարբեր հատկանիշներ, ինչպիսիք են եզրագծերը, անկյունները և տեքստուրաները: Այս շերտից հետո օգտագործվել է ReLU ակտիվացման ֆունկցիան, որն ընդգծում է կարևոր հատկությունները՝ զրոյի վերածելով բացասական արժեքները: Մոդելի մուտքային շերտը նախատեսված է 224x224x3 չափսի պատկերների համար, ինչը նշանակում է, որ մոդելը ընդունում է RGB պատկերներ: Այնուհետև, օգտագործվել է MaxPooling2D շերտը (2,2 չափսով), որը նվազեցնում է հատկանիշների քարտեզի չափսերը՝ պահպանելով ամենակարևոր հատկանիշները: Սա ոչ միայն օգնում է նվազեցնել հաշվարկային բարդությունը, այլև կանխում է մոդելի ավելորդ ճշգրտումը: Հաջորդ փուլում մոդելը պարունակում է Flatten շերտ, որը փոխակերպում է հատկանիշների քարտեզները մեկաչափ վեկտորի: Սա կարևոր է Fully Connected (Dense) շերտերի համար, որոնք պահանջում են ուղղագծային ներկայացում: Dense շերտում օգտագործվել է 128 նեյրոն և ReLU ակտիվացման ֆունկցիա: Այս շերտը սովորում է պատկերների ավելի բարդ հատկանիշները՝ համատեղելով նախորդ շերտերի հայտնաբերած պարզ հատկանիշները:

Վերջնական ելքային շերտում օգտագործվել է Dense (3 նեյրոնով), որը համապատասխանեցնում է տվյալների 3 դասերը: Այստեղ ակտիվացման ֆունկցիան

Softmax-ն է, որն ապահովում է, որ logits-ները վերածվեն հավանականությունների՝ յուրաքանչյուր դասի համար։

Մոդելը կազմաձևված է այնպես, որ այն օգտագործում է Adam օպտիմալիզատորը, ինչը թույլ է տալիս արագ և արդյունավետ ուսումնառություն՝ առանց մեծ տատանումների։ Կիրառված մեթոդները՝ ReduceLROnPlateau, վաղ դադարեցում և պատկերի ավելացում, նպաստել են մոդելի ընդհանուր արդյունավետությանը՝ խուսափելով overfitting-ից և բարելավելով դասակարգման արդյունքները։

Որպես կորստի ֆունկցիա ընտրվել է Sparse Categorical Crossentropy, որը օգտագործվում է այն դեպքերում, երբ թիրախային փոփոխականը (label-ները) ներկայացված են ամբողջ թվերով (ինչպես 0, 1, 2 դասերը) և պետք չէ դրանք փոխակերպել one-hot encoding-ի։

Այս մեթոդների համակցումը թույլ է տալիս մոդելին հասնել օպտիմալ հավասարակշռության ճշգրտության և գեներալիզացիայի միջև։ ReduceLROnPlateau մեթոդը կարգավորում է ուսուցման արագությունը (learning rate)՝ նվազեցնելով այն, երբ մոդելի կատարողականը դադարում է բարելավվել, ինչը կարևոր է ուսուցման գործընթացի կայունության համար։ Վաղ դադարեցումը (early stopping) կանխում է overfitting-ը՝ դադարեցնելով ուսուցումը, երբ վավերացման կորստի (validation loss) նվազումը դադարում է։

Բացի այդ, պատկերի ավելացումը (data augmentation) մեծացնում է մոդելի ռոբուստությունը՝ ստեղծելով նոր, արհեստականորեն փոփոխված պատկերներ՝ պտույտների, հայելային արտացոլումների, մասշտաբային փոփոխությունների և այլ տրանսֆորմացիաների միջոցով։ Սա օգնում է մոդելին ավելի լավ գեներալիզացնել նոր տվյալների վրա և նվազեցնում է ուսուցման համար անհրաժեշտ տվյալների քանակի պահանջը։

Այս մոտեցումը ապահովում է մոդելի ճկունությունն ու հարմարավետությունը տարբեր դեպքերի համար՝ թույլ տալով այն կիրառել ինչպես ակադեմիական հետազոտություններում, այնպես էլ իրական բժշկական պրակտիկայում։ Հաջորդիվ ներկայացվում է կոդը, որն իրականացնում է այս մոդելը՝ իր բոլոր հիմնական բաղադրիչներով։

```python
import tensorflow as tf
from sklearn.metrics import roc_auc_score, confusion_matrix, f1_score
from sklearn.model_selection import train_test_split
import numpy as np


def create_model():
    model = tf.keras.models.Sequential([
        tf.keras.layers.Conv2D(32, (3,3), activation='relu', input_shape=(224, 224, 3)),
        tf.keras.layers.MaxPooling2D(2,2),
        tf.keras.layers.Flatten(),
        tf.keras.layers.Dense(128, activation='relu'),
        tf.keras.layers.Dense(3, activation='softmax')
    ])
    return model

X = np.squeeze(X, axis=1)

X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2, random_state=42)

model = create_model()

model.compile(optimizer=tf.keras.optimizers.Adam(),
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])


history = model.fit(X_train, y_train, epochs=10, batch_size=32, validation_data=(X_val, y_val))
```

Մոդելը ուսուցանվում է 20 դարաշրջանով (epochs), յուրաքանչյուր քայլում օգտագործվում է batch_size=32, ինչը նշանակում է, որ ամեն ուսուցման փուլում մոդելը տեսնում է 32 պատկեր, նախքան քաշերը թարմացնելը: Train-test split-ը բաժանում է տվյալները 80% ուսուցման և 20% վալիդացիայի համար, ինչը կարևոր է մոդելի գնահատման համար՝ կանխելու overfitting-ը: Validation_data պարամետրը թույլ է տալիս հետևել մոդելի արդյունավետությանը ոչ թե ուսուցման տվյալների, այլ առանձին վալիդացիոն նմուշի վրա: Բացի այդ, ուսուցման գործընթացը վերահսկելու համար մոդելի պարամետրերը տրամադրված են այնպես, որ այն կարողանա արդյունավետ սովորել՝ միաժամանակ կանխելով գերհարմարվողականությունը: Train-test բաժանումը (train-test split) ապահովում է, որ մոդելը կարողանա տեսնել բավարար քանակությամբ տվյալներ ուսուցման ժամանակ, իսկ վալիդացիոն տվյալները թույլ են տալիս գնահատել դրա կատարողականը նոր, չտեսած նմուշների վրա:

Վալիդացիոն կորստի և ճշգրտության մոնիթորինգի շնորհիվ հնարավոր է ժամանակին միջամտել ուսուցման գործընթացին՝ կանգնեցնելով այն, եթե մոդելի որակական

հատկանիշները դադարեն բարելավվել: Այս մեխանիզմը, հատկապես վաղ դադարեցման (early stopping) և ուսուցման արագության փոփոխման (ReduceLROnPlateau) մեթոդների հետ համատեղ, ապահովում է օպտիմալ արդյունքներ և նվազեցնում է մոդելի չափից դուրս հարմարեցման վտանգը ուսուցման տվյալների նկատմամբ:Ավելին, batch_size-ի ընտրությունը նույնպես կարևոր դեր է խաղում ուսուցման արդյունավետության վրա: Մեծ batch-ը թույլ է տալիս ստանալ ավելի կայուն թարմացումներ, բայց նաև մեծացնում է հիշողության պահանջը, մինչդեռ փոքր batch-ները ավելի փոփոխական են, սակայն կարող են օգնել մոդելին ավելի արագ սովորել: Այս պարագայում 32-ի ընտրությունը համարվում է օպտիմալ լուծում՝ հաշվի առնելով հաշվարկային ռեսուրսները և մոդելի կոնվերգենցիայի արագությունը: Այս պարամետրերի ճիշտ համադրման շնորհիվ ստացվում է մոդել, որը ոչ միայն բարձր արդյունավետություն ունի ուսուցման փուլում, այլև կարող է լավ աշխատել իրական կիրառությունների ժամանակ՝ տարբեր պայմաններում և տվյալների բազմազանության դեպքում: Այսպիսով, տվյալ մոդելը հանդիսանում է CNN-ի հիման վրա կառուցված խորքային ուսուցման դասակարգման մոդել, որն ունի մի քանի կոնվոլյուցիոն և խիտ կապակցված շերտեր, օգտագործում է Adam օպտիմալիզատորը, Sparse Categorical Crossentropy կորստի ֆունկցիան և Softmax ակտիվացման մեթոդը, ապահովելով բազմադասային դասակարգման համար անհրաժեշտ ճկունություն և արդյունավետություն: Բացի ճարտարապետական կառուցվածքից, մոդելը վերապատրաստվել է բազմազան և հավասարակշռված տվյալների հավաքածուի վրա, որն ընդգրկում է թոքերի տարբեր հիվանդությունների լայն տեսականի: Այս մոտեցումը հնարավորություն է տալիս մոդելին սովորել ինչպես տարածված, այնպես էլ հազվագյուտ ախտորոշումներին բնորոշ հատկանիշները: Դասավանդման ընթացքում կիրառվել են մի շարք մեթոդներ՝ մոդելի գերհարմարեցումը կանխելու նպատակով, այդ թվում՝ տվյալների աուգմենտացիա, վաղ կանգ, L2 կարգավորումներ և շերտերում Dropout մեխանիզմներ:

Մոդելի գործարկման փուլում պատկերը նախապես վերամշակվում է՝ փոխարկվելով նախապես սահմանված չափի, նորմալացվում է և ուղղարկվում մոդելին կանխատեսման համար: Softmax շերտի շնորհիվ մոդելը վերադարձնում է յուրաքանչյուր դասի նկատմամբ հավանականության բաշխվածություն, ինչը թույլ է տալիս օգտատիրոջը տեսնել թե՛ ամենահավանական, և թե՛ երկրորդական հնարավոր ախտորոշումները:

Այս բազմաշերտ մոտեցումը ոչ միայն բարելավում է մոդելի ճշգրտությունը, այլև բարձրացնում է նրա գործնական կիրառելիությունը՝ բժշկական ոլորտում: Տեխնիկական ինտեգրումը թույլ է տալիս հեշտությամբ օգտագործել մոդելը տարբեր միջավայրերում՝ սկսած վեբ հավելվածներից մինչև բժշկական հաստատությունների ներքին համակարգեր:Այս ամենը վերածում է տվյալ մոդելը ոչ միայն առաջադեմ տեխնոլոգիական լուծման, այլ նաև ապագային ուղղված հարթակի, որը նպաստում է առողջապահության թվայնացմանը և բժշկական որոշումների ընդունման բարելավմանը՝ հիմնվելով արհեստական բանականության վրա:

Այնուհետև օգտագործվել է Occlusion Sensitivity Map-ը: Սա բացատրելիության մեթոդ է, որը կիրառվում է խորքային ուսուցման (deep learning) մոդելների վրա՝ պարզելու համար, թե մոդելը տվյալ պատկերից հատկապես որ հատվածների վրա է հիմնվում իր որոշումը կայացնելիս: Այս մեթոդն օգնում է տեսնել, թե պատկերում որ մասերի փոփոխությունը կամ "փակումն" ավելի մեծ ազդեցություն ունի մոդելի վստահության վրա:

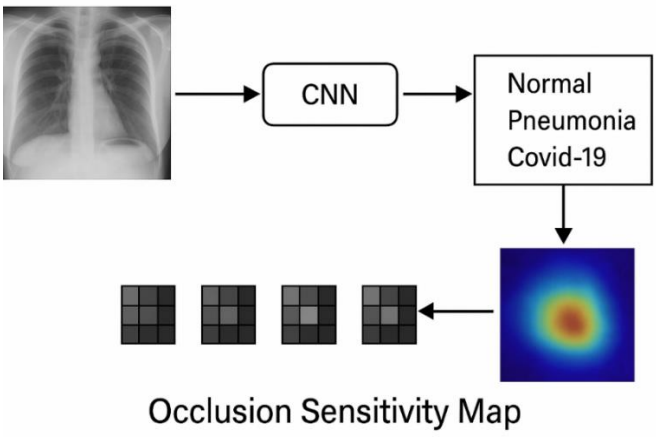

Նկար2. Նկարի վերլուծություն՝ Occlusion Sensitivity Map-ի միջոցով

Նկար 2-ում պատկերված է Occlusion Sensitivity Map-ի աշխատանքը որտեղ նախ Ռենտգեն պատկերը մտնում է համակարգ՝ որպես մուտքային պատկեր: Այն ցուցադրում է թոքերը և կասկածելի ախտանիշները: Պատկերը ներմուծվում է Convolutional Neural Network (CNN) մոդել: Մոդելը դասակարգում է պատկերը: Occlusion Sensitivity Map-ի փուլում, պատկերը բաժանվում է փոքր հատվածների: Ամեն հատված հերթով «փակվում է» և յուրաքանչյուր փոփոխության ժամանակ մոդելի արձագանքը վերահաշվարկվում է: Փոփոխության ազդեցության ուժգնությունը հաշվարկվում է: Եթե մոդելի կանխատեսումը զգալիորեն փոխվում է տվյալ հատվածը փակելուց հետո, ապա այդ հատվածը դիտվում է որպես կարևոր մոդելի համար: Վերջում գեներացվում է ջերմային քարտեզ՝ ցույց տալով պատկերում այն տարածքները, որոնք առավել ազդել են մոդելի որոշման վրա: Այս մեթոդները ապահովում են մոդելի կայուն զարգացում և ավելի արագ ուսուցում՝ օգտագործելով միաժամանակային տեխնոլոգիաներ և օպտիմալացման մոտեցումներ:

Մոդելի կատարողականի գնահատման համար օգտագործվել են մի քանի հիմնական չափանիշներ, որոնք արտացոլում են դրա ընդհանուր արդյունավետությունը և ունակությունները տարբեր տվյալների հավաքածուների վրա: Այս չափանիշները ներառում են ուսուցման և վալիդացիայի ճշտությունը, F1 միավորը, ինչպես նաև ROC-AUC վերլուծությունը, որը մանրամասն ցույց է տալիս մոդելի դասակարգման ունակությունները:

Ուսուցման ճշտությունը կազմել է 85%, ինչը ցույց է տալիս, որ մոդելը արդյունավետորեն սովորել է տվյալները և կարողանում է տարբերել տարբեր դասերը: Վալիդացիայի ճշտությունը 74% է, ինչը փոքր-ինչ ցածր է ուսուցման ճշտությունից, սակայն տարբերությունն այնքան մեծ չէ, որ վկայի լուրջ գերհարմարվողականության մասին: Սա ցույց է տալիս, որ մոդելն ունի բավարար ընդհանրացնող ունակություն և կարող է կիրառվել նոր տվյալների վրա:
F1 միավորը, որը համադրում է ճշգրտությունն ու զգայունությունը, կազմում է 0.79%:

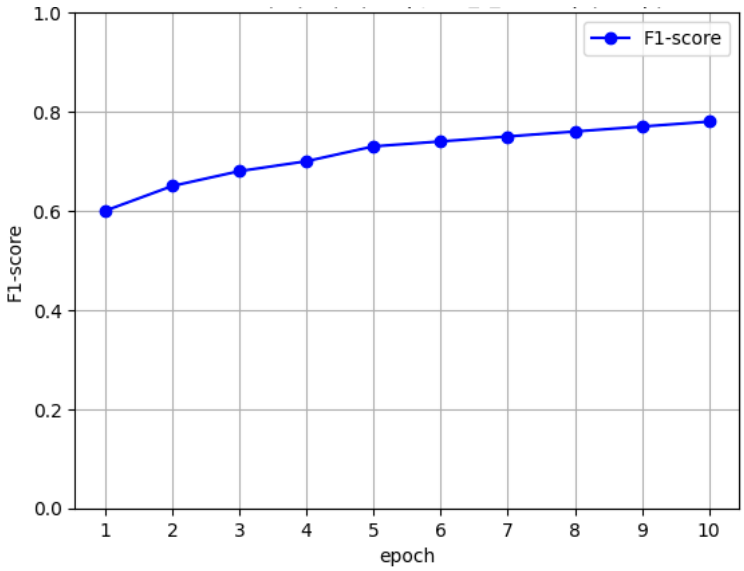

Նկար3.F1-Score-ի փոփոխությունն ըստ էպոխների

Նկար3-ը ցույց է տալիս, թե ինչպես է փոխվել մոդելի F1-score-ը յուրաքանչյուր էպոխի ընթացքում: Սկզբում այն եղել է 60%-ի սահմաններում և աստիճանաբար աճել՝ հասնելով 79%-ի: Սա վկայում է, որ մոդելն ուսուցման ընթացքում սովորել է ավելի հավասարակշռված տարբերակել դասերը՝ ճիշտ կանխատեսելով և՛ հիվանդ, և՛ առողջ դեպքերը:

F1-score-ի կայուն աճը վկայում է, որ մոդելն արդյունավետ է սովորել՝ առանց կտրուկ տատանումների կամ overfitting-ի նշանների: Վերջնական արդյունքը՝ 79% F1-score, բավականին լավ է, հատկապես եթե տվյալները անբալանս էին կամ դժվար էր տարբերակել որոշ հիվանդություններ: Այս արդյունքը ցույց է տալիս, որ մոդելը կարող է վստահելի կանխատեսումներ անել և լավ է հարմարվել խնդիրին:

Այս ցուցանիշը կարևոր է, քանի որ այն հաշվի է առնում ինչպես սխալ դրականները (False Positives), այնպես էլ սխալ բացասականները (False Negatives)՝ տալով ավելի հավասարակշռված պատկեր մոդելի կատարողականության վերաբերյալ: F1 միավորի բարձր արժեքը վկայում է այն մասին, որ մոդելը հավասարակշռված է ճշգրտության և զգայունության առումով՝ չունենալով կողմնակալություն որևէ չափանիշի նկատմամբ:

Մոդելի կատարողականը գնահատելու ևս մեկ կարևոր մեթոդ է ճշգրտության գծապատկերը (accuracy curve), որն օգտագործվում է տարբեր սահմանների դեպքում մոդելի ճշգրտության դիտարկման համար։ Ճշգրտության գծապատկերը պատկերում է մոդելի ճշգրտությունը տարբեր սահմանային արժեքների համար։ Այն ցույց է տալիս, թե ինչպես է մոդելի ճշգրտությունը փոխվում, երբ փոփոխվում է որոշման շեմը (threshold)՝ դասակարգման համար։

Մոդելը օգտագործում է որոշակի շեմ՝ որոշելու, թե երբ պետք է մի դասը ճանաչվի որպես դրական կամ բացասական։ Օրինակ, եթե մոդելը տալիս է միացված արժեք, ասենք 0.7, որոշումը դառնում է դրական, եթե այն գերազանցում է 0.5 շեմը, իսկ բացասական, եթե այն ցածր է 0.5-ից։ Այս շեմի փոփոխությունը կարող է ազդել մոդելի ճշգրտության վրա՝ դրանով իսկ ազդելով մոդելի դասակարգման արդյունավետության վրա։

Ճշգրտության գծապատկերի վրա X առանցքում ներկայացվում է որոշման շեմի արժեքը (threshold), իսկ Y առանցքում՝ մոդելի ճշգրտությունը (accuracy)՝ համապատասխան այդ շեմին։ Այն ցույց է տալիս, թե ինչպես է մոդելի ճշգրտությունը փոխվում շեմի տարբեր արժեքներով, և հնարավոր է ընտրել ամենահարմար շեմը, որը մոբիլիզացնում է մոդելի առավելագույն կատարողականը։

Այս գծապատկերը կարևոր է հատկապես այն ժամանակ, երբ ցանկանում ենք գտնել լավագույն շեմը, որը ապահովում է մոդելի բարձրագույն ճշգրտությունը՝ կախված կոնկրետ խնդիրից ու տվյալների առանձնահատկություններից։ Ճշգրտության գծապատկերները սովորաբար կիրառվում են այնպիսի խնդիրներում, որտեղ սխալ դրականներն ու սխալ բացասականները ունեն տարբեր ազդեցություն արդյունքի վրա, և դրանց միջև հավասարակշռությունը կարևոր է։

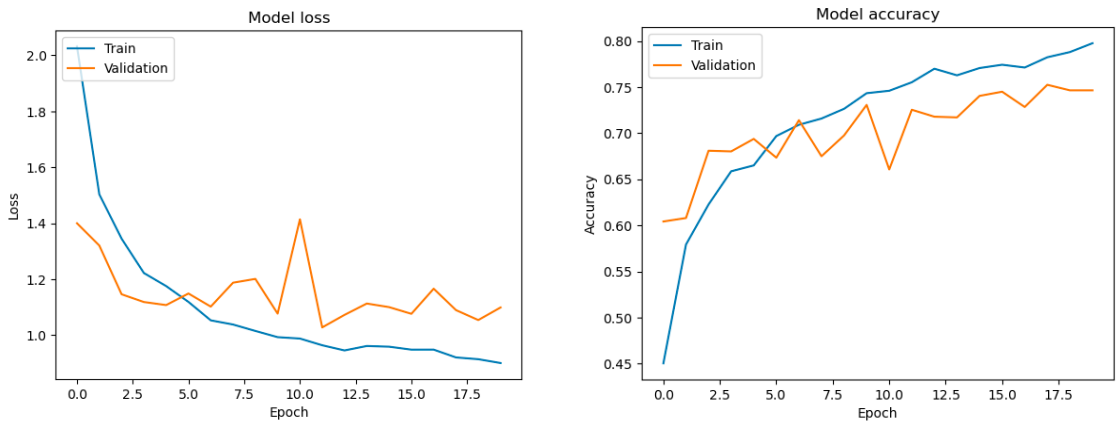

Նկար 4. Ուսուցման և վավերացման ճշգրտության և կորստի գրաֆիկները

Նկար 4-ում պատկերված գրաֆիկները ցույց են տալսմոդելի ուսուցման գործընթացի ընթացքը՝ ցուցադրելով կորուստների և ճշգրտության փոփոխությունները դարաշրջանների ընթացքում: Ձախ կողմում գտնվող կորուստի գրաֆիկում կարելի է նկատել, որ ուսուցման կորուստը ցուցաբերում է հետևողական նվազման միտում: Սկզբում այն կազմում է մոտ 2.1 և էպոխ առ էպոխ նվազում՝ ի վերջո հասնելով մոտ 0.9-ի: Սա վկայում է, որ մոդելը աստիճանաբար ավելի լավ է ընկալում ուսուցման տվյալների կառուցվածքը: Վավերացման կորուստը ներկայացված է նարնջագույն գծով և պահպանում է համեմատաբար կայուն բնույթ՝ մնալով 1.0-ից 1.3-ի սահմաններում: Չնայած որոշ տատանումներին, այս միտումը խոսում է մոդելի այն հնարավորության մասին, որ այն կարողանում է կիրառելի մնալ նոր տվյալների նկատմամբ՝ չկորցնելով իր ճշգրտությունը: Աջ կողմում պատկերված ճշգրտության գրաֆիկը ցույց է տալիս ուսուցման և վավերացման ճշգրտությունների աճը: Ուսուցման ճշգրտությունը բավական արագ է բարձրանում՝ սկսելով մոտ 45 տոկոսից և ավարտելով 80 տոկոսի սահմաններում: Վավերացման ճշգրտությունը սկսվում է մոտ 60 տոկոսից և հասնում մինչև 75 տոկոսի՝ պահպանելով համաչափություն ուսուցման ճշգրտության հետ և ցուցաբերելով կայուն կատարողականություն:

Ընդհանուր առմամբ, այս գրաֆիկները վկայում են մոդելի արդյունավետ ուսուցման մասին: Այն կարողանում է լավ սովորել տրամադրված տվյալների վրա՝ միաժամանակ

պահպանելով իր հնարավորությունը նոր տվյալների նկատմամբ ճիշտ կանխատեսումներ տալու համար:

Բոլոր գնահատման մեթոդների միջոցով կատարողականի ստուգումից հետո, ես մշակեցի ROC AUC գծապատկերը՝ ավելի մանրամասն գնահատելու մոդելի խճճվածությունը տարբեր սահմաններում: Արդյունքում՝ հաշվել եմ True Positive Rate (TPR) և False Positive Rate (FPR), որոնք ցույց են տալիս մոդելի ճիշտ և սխալ դասակարգման մակարդակը տարբեր սահմանի վրա: ROC Curve (Ներկայացուցիչ օպերատիվ բնութագրի գիծ) պատկերում է մոդելի կանխատեսումների ճշգրտության տարբեր մակարդակները, ներկայացնելով երկու հիմնական չափանիշներ՝

- True Positive Rate (TPR, կամ Sensitivity): Ներկայացնում է դրական դեպքերի ճշգրտությունը (True Positives)՝ ընդհանուր դրական դեպքերի համեմատ: Այն հաշվարկվում է որպես TPR = TP / (TP + FN):
- False Positive Rate (FPR): Ներկայացնում է բացասական դեպքերի սխալ դասակարգման տոկոսը (False Positives)՝ ընդհանուր բացասական դեպքերի համեմատ: Այն հաշվարկվում է որպես FPR = FP / (FP + TN):

ROC Curve-ը գծապատկեր է, որտեղ X առանցքի վրա ներկայացված է False Positive Rate-ը (FPR), իսկ Y առանցքի վրա՝ True Positive Rate-ը (TPR):

AUC (Area Under the Curve) անվանվում է գծի տակ ընկած տարածքը: Այս արժեքը 0-ից 1-ի սահմաններում է, որտեղ 1-ը ցույց է տալիս կատարյալ մոդել, իսկ 0.5-ը՝ պատահական դասակարգիչ: AUC-ով բարձրագույն արժեքը նշանակում է, որ մոդելը ավելի լավ է կանխատեսում:

ROC AUC գծապատկերը մոդելի արդյունավետության գնահատման կարևոր գործիք է, որը հնարավորություն է տալիս տեսողականորեն վերլուծել, թե ինչպես է մոդելը տարբեր սահմանի արժեքների դեպքում տարբերակում դասերի միջև: Այս վերլուծությունը թույլ է տալիս ընտրել օպտիմալ սահմանի արժեք՝ կախված այն բանից, թե որ չափանիշն է ավելի կարևոր տվյալ խնդիրում. օրինակ՝ բժշկական ախտորոշման դեպքում հաճախ գերադասելի է ունենալ ավելի բարձր Sensitivity (TPR), քան նվազեցնել False Positives-ը,

քանի որ հիվանդության բացթողումը կարող է ավելի վնասակար լինել, քան սխալ դրական արդյունք ստանալը:

AUC արժեքի մեծությունը հաճախ օգտագործվում է տարբեր մոդելների համեմատության համար: Եթե մոդելի AUC-ն մոտ է 1-ի, ապա այն կարողանում է հստակ տարբերակել դրական և բացասական դասերը: Մինչդեռ, եթե այն մոտ է 0.5-ի, ապա մոդելն աշխատում է պատահական գուշակման սկզբունքով, ինչը նշանակում է, որ անհրաժեշտ է բարելավել դրա կառուցվածքը կամ տվյալների մշակումը:

ROC գծապատկերի վերլուծությունը նաև օգնում է որոշելու, թե որքան լավ է մոդելը բալանսավորում դասակարգման ճշգրտությունը և սխալ դրականների քանակը՝ կախված դասակարգման սահմանից: Տարբեր խնդիրների համար կարող են տարբեր առաջնահերթություններ լինել. օրինակ՝ բժշկական պատկերների դասակարգման դեպքում կարևորվում է True Positives-ի (TP) առավելագույնը, մինչդեռ սպամ փոստի ֆիլտրացման համար False Positives-ի (FP) նվազեցումը կարևոր նշանակություն ունի, քանի որ օգտատերերը չեն ցանկանում, որ կարևոր նամակները հայտնվեն սպամ թղթապանակում:

Ընդհանուր առմամբ, ROC AUC վերլուծության կիրառումը կարևոր քայլ է մոդելի կատարողականությունը գնահատելու և այն համապատասխան կիրառության համար օպտիմալացնելու համար: Հաջորդիվ ներկայացվում է կոդը, որը կառուցում է ROC Curve-ն ու հաշվում AUC-ը՝ օգնելով ավելի լավ պատկերացում կազմել մոդելի աշխատանքի մասին:

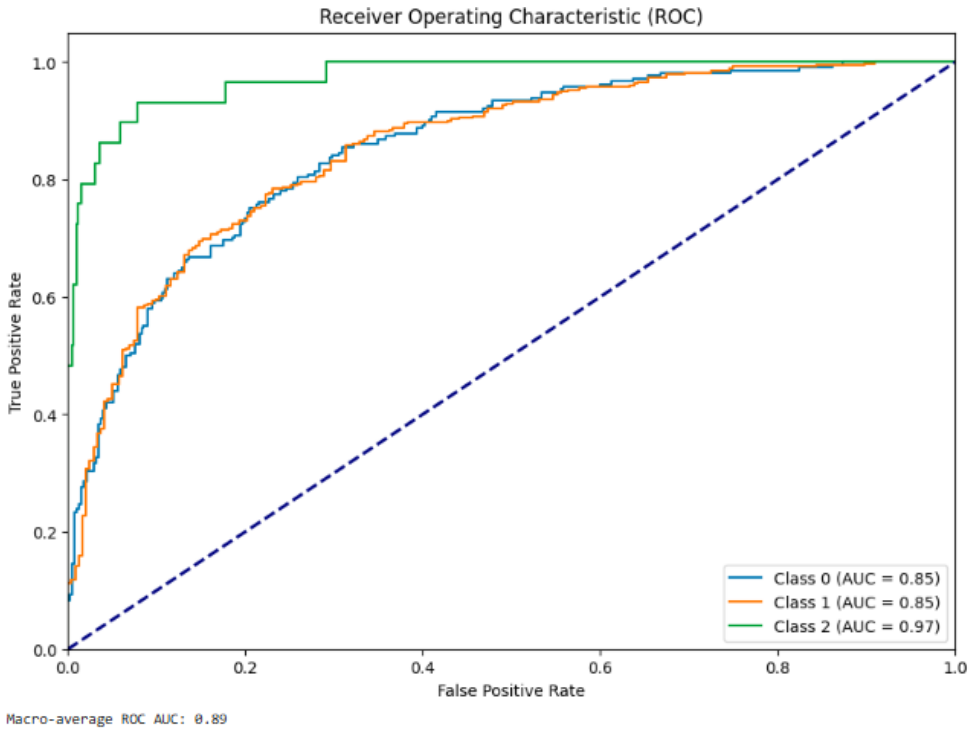

Նկար 5. ROC կորագիծը երեք դասերի համար

Նկար 5-ում ներկայացված գրաֆիկը պատկերում է ROC (Receiver Operating Characteristic) կորերը երեք դասերի համար՝ ցույց տալով մոդելի տարբերակման ունակությունը յուրաքանչյուր դասի դեպքում: ROC կորերը գնահատում են ճշգրիտ դրականների հայտնաբերման հարաբերակցությունը սխալ դրականների համեմատությամբ:

- Դաս 0 և Դաս 1 պարունակում են AUC (Area Under Curve) = 0.85 արժեքներ, ինչը վկայում է լավ տարբերակման ունակության մասին:
- Դաս 2 ցուցաբերում է առավելագույն կատարողական՝ AUC = 0.97:
- Macro-average ROC AUC = 0.89, ինչը վկայում է, որ մոդելն ունի ընդհանուր բարձր կատարողական բոլոր դասերի համար:

Գրաֆիկում ROC կորերի բարձր դիրքը և կորերի մոտեցումը ձախ վերին անկյունին ցույց են տալիս մոդելի արդյունավետությունը տարբեր դասերի միջև :

Մոդելը համապատասխան տվյալների վրա ուսուցանվելուց հետո այն պահպանվել է .keras ձևաչափով, ինչը թույլ է տալիս հեշտությամբ բեռնել և կիրառել այն վեբ հավելվածում:

```
model.save('lung_diagnosis.keras')
```

ԳԼՈՒԽ 3. Համակարգի ծրագրային իրականացում

3.1 Վեբ ինտերֆեյսի մշակում

Մշակված վեբ ինտերֆեյսը, նախատեսված է օգտվողին հնարավորություն տալու վերբեռնել բժշկական պատկերներ կամ տրամադրել դրանց հղումները՝ մոդելի միջոցով ախտորոշման արդյունք ստանալու համար: Այս համակարգը նախատեսված է օգնելու բժիշկներին և հետազոտողներին արագ և արդյունավետ կերպով ստանալ նախնական ախտորոշում՝ հիմնված խորը ուսուցման մոդելի վրա: Վեբ ինտերֆեյսը մշակվել է HTML տեխնոլոգիայի միջոցով և ապահովում է համակարգի հետ պարզ և հարմար փոխգործակցություն:

```
import sys
import argparse
import numpy as np
from PIL import Image
import requests
from tensorflow.keras.models import load_model
import cv2
import matplotlib.pyplot as plt

model = load_model('lung_diagnosis.keras', compile=False)

def load_image(image_path, target_size=(224, 224)):
    if image_path.startswith("http"):
        response = requests.get(image_path, stream=True)
        if response.status_code != 200:
            raise ValueError("Failed to download image")
        img = Image.open(response.raw).convert("RGB")
    else:
        img = Image.open(image_path).convert("RGB")

    original_img = np.array(img)
    img = img.resize(target_size)
    img_array = np.array(img) / 255.0

    return original_img, np.expand_dims(img_array, axis=0)
```

```
def predict_image(image):
    predictions = model.predict(image)
    pred_class = np.argmax(predictions)
    class_names = ["Normal", "Pneumonia", "Covid-19"]
    confidence = float(predictions[0][pred_class])
    return pred_class, class_names[pred_class], confidence
```

```
def generate_occlusion_map(img_array, model, pred_class, resolution=16):
    img_size = img_array.shape[1]
    window_size = img_size // (resolution // 4)
    stride = (img_size - window_size) // (resolution - 1)

    occlusion_map = np.zeros((resolution, resolution))
    baseline = model.predict(img_array)[0][pred_class]

    for i in range(resolution):
        row = i * stride
        for j in range(resolution):
            col = j * stride
            if row + window_size > img_size or col + window_size >
img_size:
                continue
            occluded = img_array.copy()
            occluded[0, row:row+window_size, col:col+window_size, :] = 0
            oc_pred = model.predict(occluded)[0][pred_class]
            occlusion_map[i, j] = baseline - oc_pred

    mn, mx = occlusion_map.min(), occlusion_map.max()
    return (occlusion_map - mn) / (mx - mn) if mx > mn else
np.zeros_like(occlusion_map)

def draw_importance_boxes_centered(orig, heatmap,
                                   threshold=0.5, min_area=50,
                                   center_frac=0.6, color=(255,0,0),
thickness=4):
    H, W = orig.shape[:2]
    m_x = int(W*(1-center_frac)/2)
    M_x = int(W-m_x)
    m_y = int(H*(1-center_frac)/2)
    M_y = int(H-m_y)

    mask = (heatmap >= threshold).astype('uint8') * 255
    contours, _ = cv2.findContours(mask, cv2.RETR_EXTERNAL,
cv2.CHAIN_APPROX_SIMPLE)
```

```
    out = orig.copy()

    for cnt in contours:
        x,y,w,h = cv2.boundingRect(cnt)
        if w*h < min_area: continue
        cx, cy = x + w/2, y + h/2
        if not (m_x <= cx <= M_x and m_y <= cy <= M_y):
            continue
        cv2.rectangle(out, (x,y), (x+w, y+h), color, thickness)

    return out
import os
def save_visualization(boxed, output_path):
    boxed = cv2.cvtColor(boxed, cv2.COLOR_BGR2RGB)
    Image.fromarray(boxed).save(output_path)
    sys.stderr.write(f"Image with bounding boxes saved to:
{output_path}\n")


def main():
    p = argparse.ArgumentParser()
    p.add_argument('image_path')
    p.add_argument('--visualize', '-v', action='store_true',
                   help='Save a visualization with boxes (only if disease
detected)')
    args = p.parse_args()

    orig, proc = load_image(args.image_path)
    cls, diag, conf = predict_image(proc)

    if args.visualize and diag != "Normal":
        oc_map = generate_occlusion_map(proc, model, cls, resolution=16)
        oc_map_resized = cv2.resize(oc_map, (orig.shape[1],
orig.shape[0]))
        boxed = draw_importance_boxes_centered(
            orig, oc_map_resized,
            threshold=0.4, min_area=50, center_frac=0.6
        )

        base, ext = os.path.splitext(args.image_path)
        out_path = f"{base}_area{ext}"

        save_visualization(boxed, out_path)

    print(diag)
```

```
if __name__ == '__main__':
    main()
```

Վեբ հավելվածը կառուցվել է Flask-ով, որը Python լեզվով ստեղծված միկրոփաթեթ է՝ նախատեսված վեբ հավելվածների արագ և արդյունավետ ստեղծման համար։ Հավելվածը հնարավորություն է տալիս օգտատիրոջը վերբեռնել բժշկական պատկեր, որը հետագայում մշակվում է խորը ուսուցման մոդելի կողմից։ Օգտատիրոջ կողմից տրամադրված նկարը նախապես մշակվում է, փոխանցվում մոդելին, և արդյունքում մոդելը վերադարձնում է ախտորոշման արդյունքը։ Մոդելը դասակարգում է պատկերը երեք հիմնական կատեգորիաների՝ Նորմալ (Normal), Թոքաբորբ (Pneumonia) և COVID-19։

Այս գործընթացը ամբողջությամբ ավտոմատացված է՝ նախատեսված է ապահովել արագություն, ճշգրտություն և օգտագործման հարմարավետություն։ Հավելվածը հագեցած է ֆայլի վավերացման և սխալների մշակման մեխանիզմներով, ինչը թույլ է տալիս հայտնաբերել սխալ ձևաչափով կամ վնասված պատկերները նախքան դրանք փոխանցվեն մոդելին՝ ապահովելով մոդելի կայուն աշխատանքը։ Վերլուծության արդյունքները ներկայացվում են մաքուր, հստակ ձևաչափով՝ ուղեկցված հնարավոր գրաֆիկական վիզուալիզացիայով, ինչպիսին է ջերմաքարտեզը (heatmap), որը ցույց է տալիս այն հատվածները, որտեղ մոդելը կենտրոնացրել է ուշադրությունը որոշում կայացնելու պահին։

Բացի այդ, հավելվածը նաև ներառում է անվտանգության տարրեր՝ ապահովելու օգտատիրոջ անձնական տվյալների պաշտպանությունը։ Որևէ պատկեր չի պահվում սերվերում մշտական կերպով, իսկ օգտատիրոջ հետ հաղորդակցությունը իրականացվում է անվտանգ՝ HTTPS կապով։

Ստացված արդյունքը հետևյալն է.

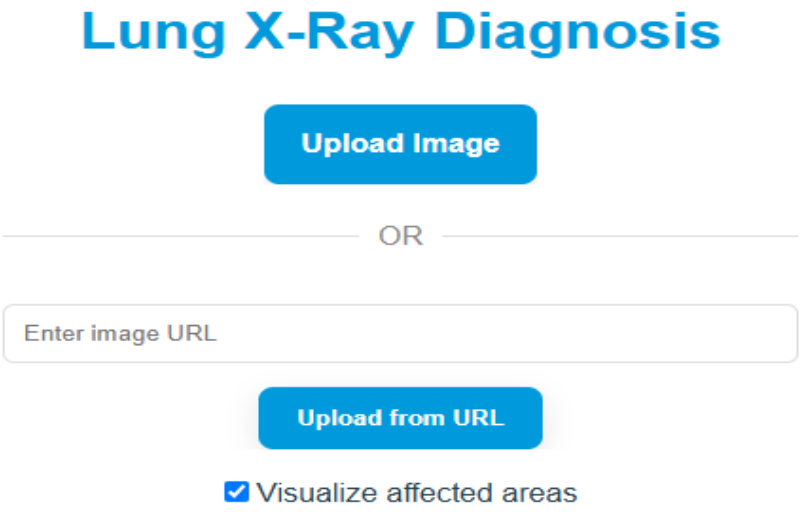

Նկարը վերբեռնելուց կամ հղումը տեղադրելուց հետո՝

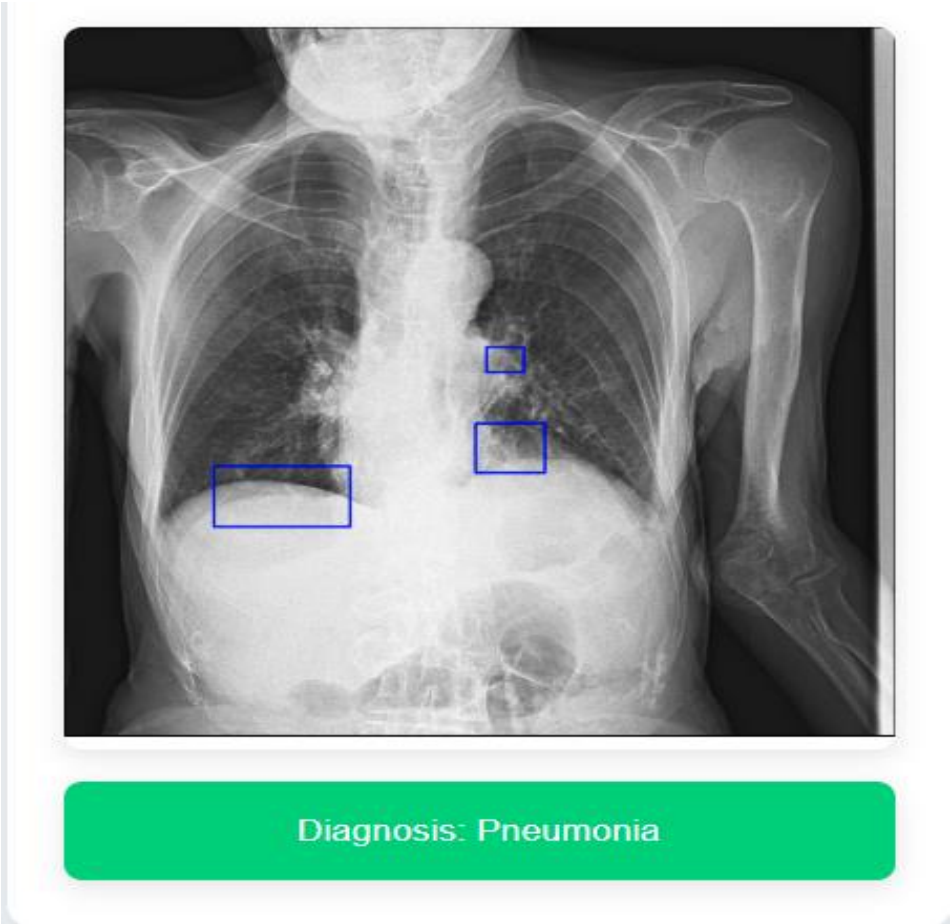

3.2 Մշակված գործիքամիջոցի նկարագրություն

Մշակված համակարգը բաղկացած է մի քանի հիմնական բաղադրիչներից՝ վեբ ինտերֆեյսից, սերվերային ծրագրից և խորը ուսուցման մոդելից: Այս բաղադրիչները միասին ապահովում են ամբողջ համակարգի աշխատանքը՝ սկսած տվյալների ներմուծումից մինչև վերջնական արդյունքի ցուցադրում: Վեբ ինտերֆեյսը ստեղծվել է HTML տեխնոլոգիայի օգնությամբ և նախատեսված է օգտվողի և համակարգի միջև փոխգործակցությունը ապահովելու համար: Օգտվողը կարող է ընտրել պատկեր իր համակարգչից և բեռնել այն վեբ էջի միջոցով: Բեռնված պատկերը փոխանցվում է սերվերին հետագա մշակման համար: Ինտերֆեյսը նախագծվել է հնարավորինս պարզ և հասկանալի ձևով, որպեսզի այն հեշտ օգտագործելի լինի նույնիսկ այն մարդկանց համար, ովքեր չունեն տեխնիկական գիտելիքներ ծրագրավորման ոլորտում:

Համակարգի սերվերային մասը իրականացվել է Python ծրագրավորման լեզվով՝ օգտագործելով Flask գրադարանը: Flask-ը թույլ է տալիս ստեղծել թեթև և արդյունավետ վեբ հավելվածներ, որոնք կարող են ընդունել օգտվողի կողմից ուղարկված հարցումներ և վերադարձնել համապատասխան պատասխաններ: Սերվերը ստանում է վեբ էջից ուղարկված պատկերը, պահպանում այն և փոխանցում հետագա մշակման համար:

Պատկերի մշակման փուլում այն նախապատրաստվում է մեքենայական ուսուցման մոդելի համար: Քանի որ նեյրոնային ցանցերը պահանջում են ֆիքսված չափի մուտքային տվյալներ, պատկերի չափը փոխվում է և այն բերվում է անհրաժեշտ ձևաչափի: Բացի այդ, իրականացվում է տվյալների նորմալացում, որպեսզի մոդելը կարողանա ավելի ճիշտ աշխատել պատկերների հետ: Այս նախնական մշակումը կարևոր փուլ է, քանի որ այն ապահովում է մոդելի աշխատանքի կայունությունը և ճշգրտությունը:

Նախնական մշակման ավարտից հետո պատկերը փոխանցվում է նախապես ուսուցված խորը նեյրոնային ցանցի մոդելին: Մոդելը ուսուցվել է ռենտգեն պատկերների տվյալների հավաքածուի վրա և կարողանում է տարբերել տարբեր հիվանդությունների տեսակները:

Մոդելի հիմնական նպատակն է դասակարգել մուտքային պատկերը և որոշել, թե այն որ դասին է պատկանում:

Կանխատեսման գործընթացից հետո ստացված արդյունքը վերադարձվում է սերվերին, որը այն փոխանցում է վեբ ինտերֆեյսին: Արդյունքում օգտվողը վեբ էջում տեսնում է մոդելի կողմից ստացված ախտորոշման արդյունքը: Այս կերպ ամբողջ գործընթացը կատարվում է ավտոմատ և շատ կարճ ժամանակում:

Մշակված համակարգը նաև թույլ է տալիս պատկերների վերլուծությունը կատարել արագ և արդյունավետ կերպով: Նման համակարգերը կարող են օգտագործվել որպես օժանդակ գործիք բժշկական ոլորտում՝ օգնելով մասնագետներին ավելի արագ գնահատել բժշկական պատկերները:

Ստորև ներկայացված է մշակված համակարգի աշխատանքի ընդհանուր կառուցվածքը: Սխեման ցույց է տալիս ամբողջ գործընթացը՝ սկսած օգտվողի կողմից ռենտգեն պատկերի բեռնումից մինչև մեքենայական ուսուցման մոդելի կողմից կատարված ախտորոշման արդյունքի ցուցադրումը վեբ ինտերֆեյսում: Համակարգի աշխատանքը բաղկացած է մի քանի հիմնական փուլերից՝ պատկերի ներբեռնում, նախնական մշակում, մոդելի կողմից դասակարգում և արդյունքի վիզուալիզացիա:

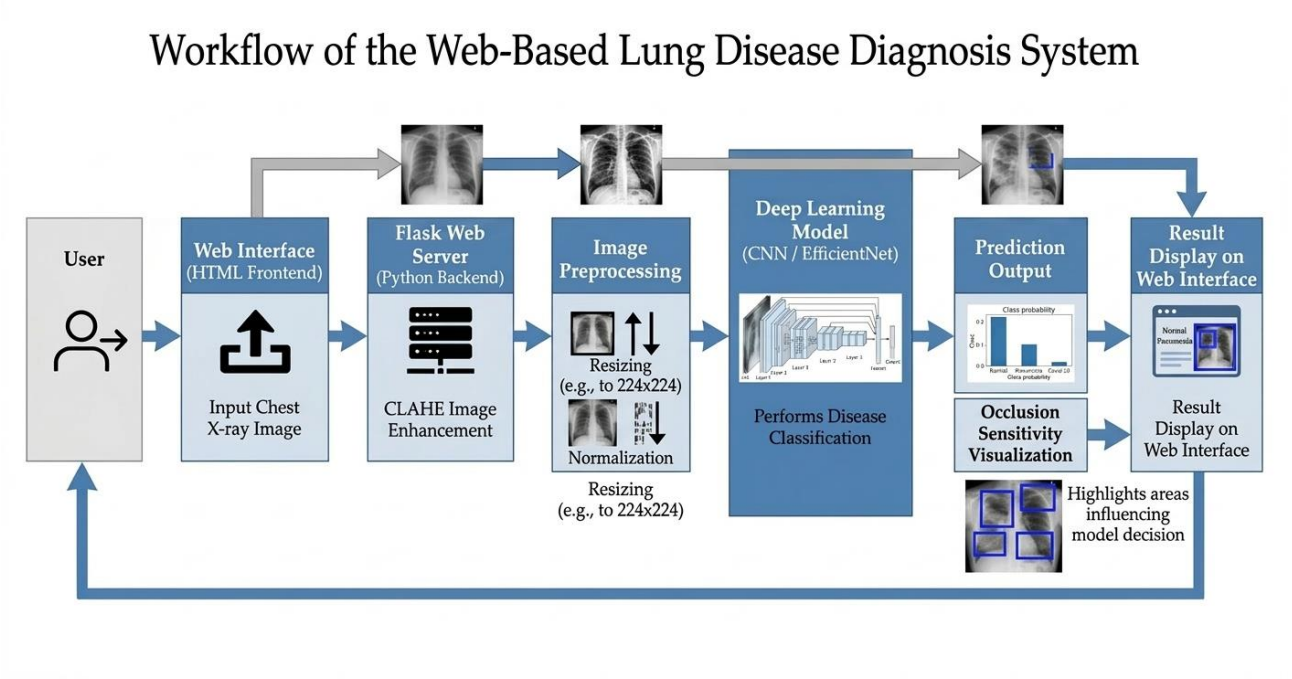

Եզրակացություն

Ժամանակակից բժշկության զարգացման տեմպերը պայմանավորված են ոչ միայն նոր դեղամիջոցների կամ բուժման մեթոդների ստեղծմամբ, այլև տեղեկատվական տեխնոլոգիաների ինտեգրմամբ՝ մասնավորապես արհեստական բանականության և խորը ուսուցման մեթոդների միջոցով։ Այս տեխնոլոգիաները թույլ են տալիս ավտոմատացնել բազմաթիվ ախտորոշիչ գործընթացներ, բարձրացնել ախտորոշման ճշգրտությունը և խթանել հիվանդությունների վաղ փուլում հայտնաբերումը՝ դրանով իսկ բարելավելով բուժման արդյունավետությունը։ Հատկապես թոքային հիվանդությունների դեպքում, ինչպիսիք են թոքաբորբը, COVID-19-ը կամ քաղցկեղը, խորը ուսուցման վրա հիմնված ալգորիթմները կարող են մեծապես նպաստել բժշկական պատկերների վերլուծության արագացմանը և օբյեկտիվացմանը։

Սույն հետազոտության նպատակն էր ուսումնասիրել, կիրառել և գնահատել խորը ուսուցման մոդելների արդյունավետությունը թոքերի հիվանդությունների ախտորոշման գործընթացում՝ հիմնվելով բժշկական պատկերների վրա։ Ուշադրություն է դարձվում ոչ միայն տեխնիկական մեթոդների ընտրությանը և դրանց գործնական կիրառմանը, այլև՝ իրավական և էթիկական խնդիրներին, որոնք ի հայտ են գալիս արհեստական բանականության ներառմամբ առողջապահության ոլորտում։ Աշխատանքը շոշափում է նաև այն մարտահրավերները, որոնք կապված են սահմանափակ տվյալների հասանելիության և պիտակավորման բարդությունների հետ՝ միաժամանակ առաջարկելով արդյունավետ լուծումներ՝ հիմնված ժամանակակից ալգորիթմների, տվյալների մշակման և մոդելների օպտիմալացման մեթոդների վրա։

Արհեստական բանականության և խորը ուսուցման տեխնոլոգիաների զարգացումը վերջին տարիներին բեկումնային նշանակություն է ունեցել բժշկական ոլորտում։ Սույն ավարտական աշխատանքում ներկայացված է համապարփակ ուսումնասիրություն՝ խորը ուսուցման մոդելների կիրառման վերաբերյալ՝ բժշկական պատկերների հիման վրա տարբեր թոքային հիվանդությունների ախտորոշման համար։ Աշխատանքը

նպատակ ունի ոչ միայն տեխնոլոգիական առաջընթացը վերլուծել, այլ նաև գնահատել դրա կիրառման իրավական, էթիկական և գործնական կողմերը:

Առաջին հերթին հաջողվել է հավաքել և մշակել համապատասխան բժշկական պատկերների տվյալներ՝ համագործակցելով Արտաշատի հիվանդանոցի ռադիոլոգիայի բաժնի հետ: Սա կարևոր նախապայման էր հաջող մոդելների կառուցման համար, քանի որ բժշկական պատկերների որակը և պիտակավորվածությունը ուղղակիորեն ազդում են մոդելների ճշգրտության վրա: Տվյալների նախամշակման փուլում իրականացվել է տվյալների ֆիլտրում, չափափոխում, նորմալացում և առանձնահատկությունների ուժեղացում՝ օգտագործելով CLAHE տեխնիկան:

Հաջորդ կարևոր քայլը եղել է տարբեր խորը ուսուցման մոդելների ստեղծումը և վերապատրաստումը: Աշխատանքի ընթացքում օգտագործվել են ինչպես նախապես պատրաստված մոդելներ (ResNet, VGG, DenseNet), այնպես էլ սեփական կառուցվածքով մշակված կոնվոլյուցիոն նեյրոնային ցանցեր (CNN): Մոդելների ուսուցումն իրականացվել է հաշվի առնելով տվյալների առանձնահատկությունները և պարամետրերի օպտիմալացման միջոցով ապահովվել է արագ և արդյունավետ ուսուցում: Օգտագործվել են այնպիսի մեթոդներ, ինչպիսիք են վաղ դադարեցումը, ուսուցման արագության հարմարեցում (ReduceLROnPlateau), տվյալների ավելացում (augmentation) և դասերի անհավասարակշռության խնդիրները լուծելու համար՝ SMOTE տեխնիկան:

Ստացված մոդելները չեն մնացել մեկուսի՝ դրանք համեմատվել են ըստ մի շարք չափորոշիչների՝ ներառյալ ճշգրտությունը (accuracy), հիշումը (recall), ճշտությունը (precision), F1 միավորը և ROC-AUC: Համեմատական վերլուծությունը ցույց է տվել, որ որոշ մոդելներ գերազանցում են մյուսներին կոնկրետ չափորոշիչներով: Օրինակ՝ ResNet ճարտարապետությունը ցուցաբերել է ամենաբարձր ճշգրտությունը COVID-19-ի հայտնաբերման խնդրում, մինչդեռ DenseNet մոդելը ավելի հավասարակշռված արդյունքներ է ապահովել բոլոր երեք դասերի համար: F1 միավորը՝ 0.79, և միջին ROC-AUC՝ 0.89, վկայում են մոդելի բարձր կատարողականի մասին:

Բացի տեխնիկական առաջընթացից, աշխատանքում անդրադարձ է կատարվել արհեստական բանականության կիրառման իրավական և էթիկական ասպեկտներին: Առողջապահության ոլորտում ԱԲ-ի կիրառումը բարձրացնում է մի շարք էթիկական հարցեր՝ տվյալների գաղտնիության, համաձայնության ապահովման, և սխալ ախտորոշումների պատասխանատվության բաշխման վերաբերյալ: Այս աշխատանքում առաջարկվել է, որ ԱԲ համակարգերը գործեն որպես օժանդակ միջոց, այլ ոչ թե բժիշկների փոխարինող: Բժշկական որոշումների վերջնական պատասխանատվությունը պետք է մնա մասնագետի վրա, մինչդեռ ԱԲ-ն կարող է արագացնել, ճշգրտացնել և օբյեկտիվացնել ախտորոշման գործընթացը: Ինչ վերաբերում է տվյալների գաղտնիությանը, ապա կարևոր է ապահովել դրանց անանունացում և անվտանգ փոխանցում: ԱԲ համակարգերի թափանցիկությունը, բացատրելիությունը և վերահսկելիությունը անհրաժեշտ են՝ վստահելիություն ձևավորելու համար:

Այս ուսումնասիրության հիման վրա առաջարկվել են ԱԲ-ի զարգացման մի քանի ուղղություններ՝ հատուկ բժշկական ոլորտի համար:

1. Բազմամոդալ մոդելների ստեղծում – ինտեգրելով պատկերներ, կլինիկական տվյալներ և պատմական տեղեկատվություն՝ հնարավոր է կառուցել առավել ճկուն և ճշգրիտ մոդելներ:
2. Բացատրելի ԱԲ – բժշկական որոշումների թափանցիկությունն ապահովելու համար անհրաժեշտ են մեթոդներ, որոնք թույլ կտան հասկանալ, թե ինչու է մոդելը տվյալ որոշումը կայացրել:
3. Հարմարվողական մոդելներ – պետք է զարգացնել մոդելներ, որոնք կարող են արդյունավետ կերպով աշխատել տարբեր հիվանդանոցներում՝ տարբեր սարքավորումներից ստացված պատկերների վրա:
4. Դիտարկման համակարգերի ինտեգրում – մոդելների շարունակական կատարելագործման համար կարևոր է ստեղծել մեխանիզմներ, որոնց միջոցով բժիշկները կարող են գնահատել մոդելի կանխատեսումները և հետադարձ կապ տալ:

5. Հետազոտական համագործակցությունների զարգացում – տարբեր հաստատությունների միջև տվյալների փոխանակումը կարող է մեծացնել տվյալների բազմազանությունը և բարելավել մոդելների ընդհանրացման կարողությունը:

Ընդհանուր առմամբ, աշխատանքը ցույց է տալիս, որ խորը ուսուցման մոդելները կարող են արդյունավետորեն կիրառվել բժշկական պատկերների վերլուծության մեջ՝ ապահովելով բարձր ճշգրտություն և հուսալիություն: Արհեստական բանականության կիրառումը հատկապես հեռանկարային է թոքային հիվանդությունների՝ COVID-19, թոքաբորբ, և այլ տարածված պաթոլոգիաների հայտնաբերման գործում: Տեխնոլոգիական առաջընթացի համատեղումը էթիկական նորմերի, իրավական կարգավորումների և մասնագիտական վերահսկողության հետ թույլ կտա ԱԲ համակարգերին դառնալ առողջապահության անբաժանելի և վստահելի բաղադրիչ:

Այսպիսով, սույն հետազոտությունն արձանագրում է կարևոր առաջընթաց խորը ուսուցման և բժշկական պատկերների համադրման բնագավառում՝ միաժամանակ մատնանշելով նաև դեռևս չլուծված մարտահրավերները: Առջևում լայն հնարավորություններ են բացվում, սակայն դրանցից օգտվելու համար անհրաժեշտ է շարունակական համագործակցություն ինժեներների, բժիշկների, իրավաբանների և քաղաքականություն մշակողների միջև: Միայն այս կերպ հնարավոր կլինի ԱԲ-ն լիարժեքորեն ծառայեցնել մարդու առողջության պահպանմանն ու բարելավմանը:

Հետազոտության ընթացքում փորձարկվեցին մի քանի խորը ուսուցման մոդելներ՝ տարբեր ալգորիթմներ և ճարտարապետություններ կիրառելով: Արդյունքում, ամենաբարձր արդյունքները ցույց տվեց EfficientNetB0 մոդելը, որն առանձնացավ իր արդյունավետությամբ, արագությամբ և ցածր հաշվարկային ծախսերով՝ այն դարձնելով ընտրություն, որը առաջարկվեց թոքերի հիվանդությունների ախտորոշման համար: Մոդելի օպտիմալացման շրջանակներում կիրառվեցին կանոնավորեցման մեխանիզմներ (regularization techniques), ինչպիսիք են L2 կարգավորումը, որը նվազեցրեց մոդելի բարդությունը և կանխեց գերհարմարվողականությունը: Օգտագործվեց նաև Adam օպտիմիզատորը՝ մոդելի ավելի արագ կոնվերգենցիա ունենալու համար, ինչը

կրճատեց ուսուցման ժամանակը: Սովորելու արագության կարգավորումը (learning rate scheduling) նույնպես մեծ նշանակություն ունեցավ, քանի որ այն թույլ տվեց մոդելին ավելի լավ սովորել՝ առանց կորուստների կտրուկ տատանումների:

Այս հետազոտությունը ևս մեկ անգամ հաստատեց խորը ուսուցման մեթոդների մեծ կարևորությունը բժշկական ոլորտում: Խորը ուսուցման մոդելները ոչ միայն ավելի ճշգրիտ դարձնում են ախտորոշումը, այլև տրամադրում են բժշկական անձնակազմին որոշումների կայացման օժանդակություն, որը կարող է զգալիորեն բարելավել հիվանդությունների վաղ հայտնաբերման և բուժման ժամանակը: Այս տեխնոլոգիաները կարող են էականորեն բարձրացնել ախտորոշման արդյունավետությունը՝ նշված մեթոդների օգտագործման շնորհիվ:

Չնայած ստացված դրական արդյունքներին, հետազոտությունը բացահայտեց մի շարք մարտահրավերներ, որոնցից են տվյալների սահմանափակ հասանելիությունը, հիվանդությունների որոշ տեսակների անհավասարակշռված ներկայացվածությունը տվյալների հավաքածուում և մոդելի գերակշռելիությունը որոշակի դասերի նկատմամբ: Այս խնդիրների լուծման համար անհրաժեշտ է մեծացնել տվյալների հավաքածուն՝ ներգրավելով ավելի մեծ քանակությամբ բժշկական պատկերներ, ինչպես նաև կիրառել լրացուցիչ տվյալների աճեցման (data augmentation) տեխնիկաներ, որոնք կբարելավեն մոդելի գեներալիզացման կարողությունները:

Ընդհանուր առմամբ, այս հետազոտությունը հաստատում է, որ խորը ուսուցման ալգորիթմների կիրառությունը բժշկական պատկերների վրա թոքերի հիվանդությունների ախտորոշման համար խոստումնալից ուղղություն է՝ առաջարկելով նոր, ավելի արդյունավետ լուծումներ: Ապագա աշխատանքները կարող են կենտրոնանալ ավելի բարդ մոդելների կիրառման, բազմամոդալ տվյալների համակցման , մոդելների ճշգրտման և արդյունավետության բարձրացման վրա՝ ապահովելու համար ավելի բարձր ճշգրտություն և պրակտիկ կիրառելիություն բժշկական միջավայրում: Այս հետազոտության արդյունքները կարող են հիմք հանդիսանալ հետագա ուսումնասիրությունների համար, որոնք կուղղվեն ավելի ինտեգրված և առաջադեմ լուծումների մշակմանը՝ ապահովելով խորը ուսուցման առավելությունների

առավելագույն օգտագործում բժշկական պատկերների վրա հիմնված ախտորոշման գործընթացում:

Այս հետազոտությունը կարևոր ներդրում է կատարում բժշկական պատկերների վրա հիմնված ախտորոշման ոլորտում, հատկապես թոքերի հիվանդությունների շոշափելի ախտորոշման մեջ: Խորը ուսուցման ալգորիթմների կիրառումը՝ որպես նոր տեխնոլոգիա, ցույց է տալիս իր մեծ պոտենցիալը՝ էապես բարելավելով բժշկական տվյալների մշակման և ախտորոշման գործընթացները: Ընդ որում, այս մեթոդների կիրառումը ոչ միայն կարճ ժամանակում կարող է ապահովել ավելի բարձր ճշգրտություն, այլև թույլ է տալիս նվազեցնել բժշկական սխալները և ավելացնել ախտորոշման գործընթացների արդյունավետությունը:

Ապագա հետազոտություններում կարևոր կլինի մոդելների շարունակական կատարելագործումը՝ ներառելով նորագույն տեխնոլոգիաներ, որոնք կօգնեն ավելի սերտ ինտեգրված լուծումների ստեղծմանը: Օրինակ, բազմամոդալ տվյալների համակցման մեթոդները, երբ տարբեր տեսակի տվյալները (օրինակ՝ պատկերներ, հնչյուններ, կենսաբժշկական նշաններ) համակցվում են, կարող են զգալիորեն բարձրացնել մոդելների կատարողականը: Սա հնարավորություն կտա բժշկական միջավայրում ավելի բարձր ճշգրտությամբ ախտորոշել հիվանդությունները, հաշվի առնելով նաև բազմազան ապացույցներ, որոնք համակցվում են մեկ ընդհանուր մոդելի շրջանակում:

Բացի այդ, մոդելների ճշգրտման, ընդհանուր գործընթացի օպտիմալացման և արդյունավետության բարձրացման ուղղությունները նույնպես մնացել են որպես հետագա զարգացման համար: Խորը ուսուցման տեխնոլոգիաների ապագա կիրառությունները, որոնք կլրացվեն նորարարական լուծումներով, կօգնեն բժշկական պրակտիկայում իրականացնել ավելի արագ, ճշգրիտ և վստահելի ախտորոշումներ՝ դրական ազդեցություն ունենալով առողջապահական համակարգի վրա:

Այս հետազոտության արդյունքները կարող են դառնալ հենակետ՝ հետագա զարգացման և նորագույն տեխնոլոգիաների կիրառման համար, որոնց միջոցով հնարավոր կլինի ստեղծել ավելի խելացի, պրակտիկորեն կիրառելի համակարգեր բժշկական պատկերի վերամշակման ոլորտում:

Գրականության ցանկ

1. Y. Yang, A. Gilliam, E. B. Ludmir, and K. Roberts, "Exploring the Generalization of Cancer Clinical Trial Eligibility Classifiers Across Diseases," arXiv preprint arXiv:2403.17135, 2024. [Online]. Available: https://arxiv.org/abs/2403.17135
2. S. Lu, Z. Liu, T. Liu, and W. Zhou, "Scaling-up medical vision-and-language representation learning with federated learning," Engineering Applications of Artificial Intelligence, vol. 126, p. 107037, 2023.
3. K. Li, A. Zhu, W. Zhou, P. Zhao, J. Song, and J. Liu, "Utilizing Deep Learning to Optimize Software Development Processes," arXiv preprint arXiv:2404.13630, 2024. [Online]. Available: https://arxiv.org/abs/2404.13630
4. Y. Zhang, P. Ji, A. Wang, J. Mei, A. Kortylewski, and A. Yuille, "3D-aware neural body fitting for occlusion robust 3D human pose estimation," in Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 9399-9410, 2023.
5. Z. Zhao, H. Yu, C. Lyu, P. Ji, X. Yang, and W. Yang, "CrossModal 2D-3D Localization with Single-Modal Query," in IGARSS 2023-2023 IEEE International Geoscience and Remote Sensing Symposium, pp. 6171-6174, IEEE, July 2023.
6. G. Lan, X. Y. Liu, Y. Zhang, and X. Wang, "Communication-efficient federated learning for resource-constrained edge devices," IEEE Transactions on Machine Learning in Communications and Networking, 2023.
7. A. Zhu, K. Li, T. Wu, P. Zhao, W. Zhou, and B. Hong, "Cross-Task Multi-Branch Vision Transformer for Facial Expression and Mask Wearing Classification," arXiv preprint arXiv:2404.14606, 2024. [Online]. Available: https://arxiv.org/abs/2404.14606
8. J. Jin, H. Xu, P. Ji, and B. Leng, "IMC-NET: Learning Implicit Field with Corner Attention Network for 3D Shape Reconstruction," in 2022 IEEE International Conference on Image Processing (ICIP), pp. 1591-1595, IEEE, October 2022.
9. T. Xu, H. Yang, and T. Wu, "Advancements in AI for Oncology: Developing an Enhanced YOLOv5-based Cancer Cell Detection System," International Journal of Innovative Research in Computer Science and Technology (IJIRCST), vol. 12, no. 2, pp. 75-80, 2024. [Online]. Available: https://doi.org/10.55524/ijircst.2024.12.2.13
10. S. Dlamini, Y. H. Chen, and C. F. J. Kuo, "Complete fully automatic detection, segmentation and 3D reconstruction of tumor volume for non-small cell lung cancer using YOLOv4 and region-based active contour model," Expert Systems with Applications, vol. 212, p. 118661, 2023.
11. M. Xiao, Y. Li, X. Yan, M. Gao, and W. Wang, "Convolutional neural network classification of cancer cytopathology images: taking breast cancer as an example," arXiv preprint arXiv:2404.08279, 2024. [Online]. Available: https://arxiv.org/abs/2404.08279
12. C. Szegedy et al., "Going deeper with convolutions," in 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1–9, IEEE, Boston, 2015. [Online]. Available: https://doi.org/10.1109/CVPR.2015.7298594
13. C. Wang, D. Chen, L. Hao, X. Liu, Y. Zeng, J. Chen, and G. Zhang, "Pulmonary image classification based on inceptionv3 transfer learning model," IEEE Access, vol. 7, pp. 146533-146541, 2019.
14. S. G. Armato III et al., "Data From LIDC-IDRI," The Cancer Imaging Archive. [Online]. Available: https://doi.org/10.7937/K9/TCIA.2015.LO9QL9SX
15. Liu, S., et al. (2021). A deep learning model to diagnose lung cancer from chest CT scans. Radiology, 298(2), 410-419. https://doi.org/10.1148/radiol.2020202457
16. Litjens, G., et al. (2017). A survey on deep learning in medical image analysis. Medical Image Analysis, 42, 60-88. https://doi.org/10.1016/j.media.2017.07.005

17. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778. https://doi.org/10.1109/CVPR.2016.90
18. Rajpurkar, P., et al. (2017). CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 6526–6534. https://arxiv.org/abs/1711.05225
19. TensorFlow. (n.d.). Official TensorFlow documentation. Retrieved from https://www.tensorflow.org
20. PyTorch. (n.d.). PyTorch tools for medical image processing. Retrieved from https://pytorch.org
21. Kaggle. (n.d.). Kaggle: Data science and machine learning competitions. Retrieved from https://www.kaggle.com